



**MATEMATICKO-FYZIKÁLNÍ
FAKULTA**
Univerzita Karlova

BAKALÁŘSKÁ PRÁCE

Jiří Balhar

Extrakce melodie pomocí hlubokého učení

Ústav formální a aplikované lingvistiky

Vedoucí bakalářské práce: Mgr. Jan Hajič

Studijní program: Informatika

Studijní obor: Programování a softwarové systémy

Praha 2019

Prohlašuji, že jsem tuto bakalářskou práci vypracoval(a) samostatně a výhradně s použitím citovaných pramenů, literatury a dalších odborných zdrojů.

Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona v platném znění, zejména skutečnost, že Univerzita Karlova má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle §60 odst. 1 autorského zákona.

V dne

Podpis autora

Poděkování.

Název práce: Extrakce melodie pomocí hlubokého učení

Autor: Jiří Balhar

Ústav: Ústav formální a aplikované lingvistiky

Vedoucí bakalářské práce: Mgr. Jan Hajič, ústav

Abstrakt: Abstrakt.

Klíčová slova: klíčová slova

Title: Melody Extraction using Deep Learning

Author: Jiří Balhar

Institute: Institute of Formal and Applied Linguistics

Supervisor: Mgr. Jan Hajič, institute

Abstract: Abstract.

Keywords: key words

Obsah


1 Úvod	3
Úvod	3
1.1 Definice melodie	6
2 Související práce	8
2.1 Průzkum existujících metod	8
2.1.1 Spektrální analýza	9
2.1.2 Funkce salience	11
2.1.3 Hledání melodie	13
2.2 Srovnání existujících metod	13
3 Datasetsy	14
3.1 Struktura dostupných dat a jejich přehled	15
3.2 MedleyDB	15
3.3 MDB-synth	16
3.4 Orchset	17
3.5 Weimar Jazz Database	18
4 Evaluace metod	19
4.1 MIREX	19
4.2 Trénovací, validační a testovací množina	19
4.3 Kvalitativní příklady	20
4.4 Metriky	20
4.4.1 Formát výstupu	20
4.4.2 Definice metrik	20
4.4.3 Další metriky	22
5 Experimenty	24
5.1 Architektura CREPE	24
5.1.1 Replikace výsledků CREPE	25
5.1.2 CREPE pro extrakci melodie	26
5.1.3 Vliv rozlišení diskretizace výšky noty	27
5.1.4 Vliv rozptylu cílové pravděpodobnostní distribuce výšky noty	28
5.1.5 Vliv šířky vstupního okna	29
5.1.6 Vliv násobného rozlišení první konvoluční vrstvy	30
5.2 Architektura WaveNet	31
5.2.1 Baseline na základě Martak a kol. (2018)	32
5.2.2 Vliv počtu filtrů dilatačních vrstev a skip propojení	34
5.2.3 Systematické prohledávání počtu dilatačních vrstev a bloků	35
5.2.4 Vliv velikosti šířky kernelu dilatací	36
5.2.5 Vliv výstupní transformace skip propojení	37
5.2.6 Vliv velikosti první konvoluce	38
5.2.7 Vliv návrhu posledních vrstev	38
6 Výsledky	40

Závěr	41
Seznam použité literatury	42
Seznam obrázků	46
Seznam tabulek	47
Seznam použitých zkratek	48
Přílohy	49

1. Úvod

Spolu s harmonií a rytmem představuje melodie základní stavební kámen většiny existující hudby. V průběhu vývoje od folklórních zpěvů přes orchestrální skladby po soudobou elektroniku si melodie téměř vždy zachovávala své dominantní postavení nositele esence jednotlivých písní. Melodie je to hlavní, co si člověk po poslechu skladby odnáší a nejsnadněji vybaví, a její důležitost je zejména v našem kulturním kontextu natolik jednoznačná, že je občas těžké si bez ní vůbec hudbu představit.

Tato práce se zabývá metodami odhadu fundamentální frekvence melodie ze zvukové nahrávky. Jinými slovy chceme získat v každém bodě vstupní skladby informaci o tom, zda melodie zní a její případnou výšku. Jde o jednu z nejdůležitějších a zároveň nejtěžších úloh z oboru *Music Information Retrieval*, jejíž rozsah využití v této doméně pokrývá významnou část aktivně řešených, otevřených problémů. Spolehlivý přepis melodie by usnadnil vyhledávání v hudebních datech, ať už na základě notového zápisu (*Symbolic Melodic Similarity*), pomocí nekvalitní nahrávky z rádia (*Audio Fingerprinting*), pomocí broukání (*Query by Singing/Humming*) nebo dokonce pomocí coveru hledané písně (*Audio Cover Song Identification*). Mimo vyhledávání by byl algoritmus užitečný pro další zpracování zvukového signálu, ať už pro manipulaci a úpravu melodického hlasu (například software *Melodyne*), nebo naopak jeho odstranění a vytvoření karaoke doprovodu (*Informed Source Separation*). V neposlední řadě by extrakce melodie pomohla při kategorizaci hudebních dat, například podle žánru (*Genre Classification*, Salamon a kol. (2012)) nebo podle zpěváka (*Singer Characterization*). A konečně široké spektrum využití by našla i v muzikologii (případně etnomuzikologii) pro kvantitativní i kvalitativní studii hudebních motivů a postupů (V jazzu například Pfeleiderer a kol.).



Obrázek 1.1: Příklad vstupu a výstupu metody pro extrakci melodie. **přidat zvukový příklad do přílohy**

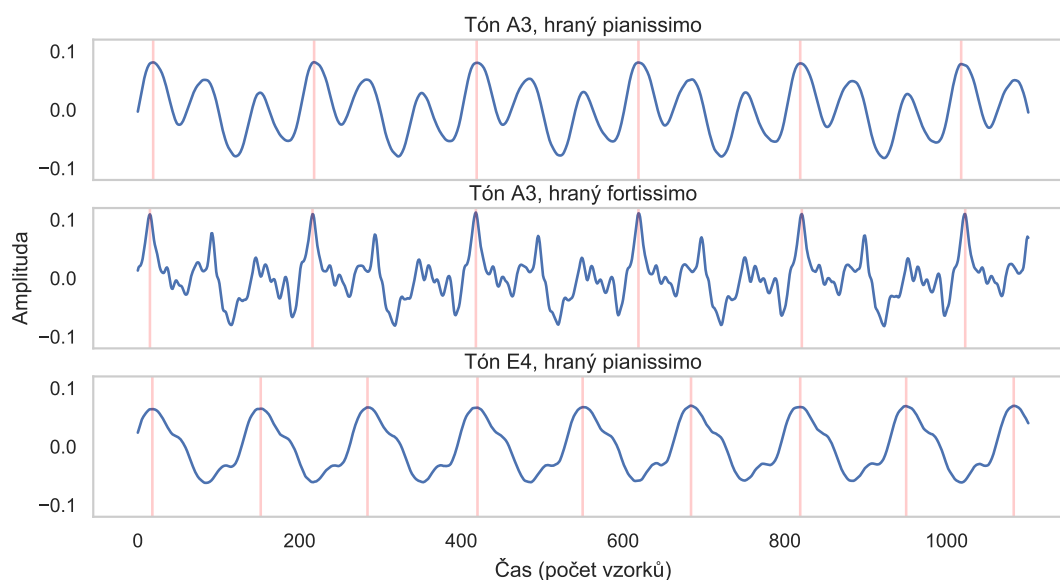
Extrakce melodie však nemusí sloužit pouze jako mezikrok pro řešení jiné úlohy, užitečný je i samotný výstup algoritmu, znázorněný na obrázku 1.1. Motivativním příkladem použití může být pomoc při transkripci. Představíme-li si začínajícího hráče na saxofon, který si chce do not přepsat své oblíbené jazzové sólo, výstup algoritmu mu dá užitečnou informaci o tom, jaký tón zní v jakou chvíli. Z této reprezentace už pak hráči zbývá nalezené tóny projít a zapsat je do notové osnovy.

Proč je ale extrakce melodie otevřený problém? Příbuzná úloha, která spočívá v přepisu nahrávky jednoho izolovaného nástroje, je v podstatě vyřešena (Mauch a Dixon, 2014), proč se tato úloha po přidání hudebního doprovodu stává výrazně obtížnější? Pro vysvětlení dvou zásadních obtíží, které se s přepisem nahrávky pojí, musíme nejdříve přiblížit vůbec povahu zvuku a možnosti jeho zkoumání.

Naše zkušenost se zvukem probíhá primárně skrze sluch. Teprve na hlasitém koncertu však člověk pocítí, že zvuk je ve své fyzikální podstatě změna tlaku vzduchu, putující od zdroje k posluchači. Díky sluchu z těchto vibrací dokážeme oddělit jednotlivé zdroje a identifikovat v nich i velmi jemné rozdíly. Ačkoli jde o subjektivní vjemy, zvuky lze částečně rozřadit podle toho, jak snadno v nich rozeznáme nějakou konkrétní výšku.

Čtenář této práce si nyní může postupně vybavit: hrající violoncello, odbíjení kostelního zvonu, cinknutí příboru, štěkot psa, plynutí potoka, šelest listí stromů, trhání papíru, tlesknutí a prasknutí balónku.

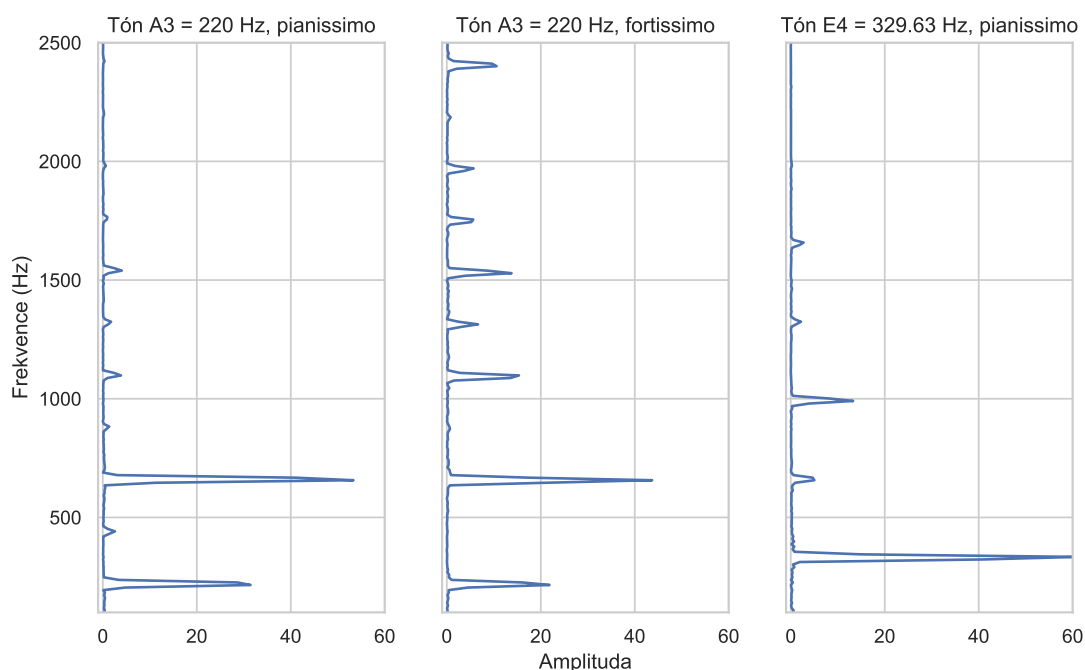
Se ztrácející se zřetelností výšky nejprve přijdeme o možnost zpívat společně se zdrojem zvuku v harmonii a posléze i o možnost si představit „vyšší“ a „nižší“ instance toho samého zvuku (jak zní vysoké a nízké prasknutí balónku?). To, co mají první z uvedených příkladů společné, je výraznější periodicitu jejich signálu — daný tlakový průběh se opakuje v čase. Díky sluchu tuto periodicitu interpretujeme jako výšku, přičemž různé výšky se od sebe liší frekvencí, se kterou se signál opakuje. Hudební nástroje jsou jedním ze zdrojů těchto pravidelných vibrací, jejichž frekvenci lze zpravidla měnit (pomocí klapky, pohybu prstu po struně, atd.). Hlas nástroje však není charakteristický pouze svou výškou, nýbrž i barvou. Ta je určena podobou signálu v rámci jedné periody.



Obrázek 1.2: Zvuk klarinetu, tóny s různou výškou a dynamikou, 25 milisekund signálu se vzorkovací frekvencí 44 100 Hz. **nějak uvést zdroj zvuku https://www.philharmonia.co.uk/explore/sound_samples/clarinet?p=3**

Na obrázku 1.2 můžeme srovnat tři tóny hrané klarinetem, první dva mají stejnou výšku, jsou ale zahráné s různou intenzitou (dynamikou) **je tohle správně**

formulované, vím že dynamika není intenzita, ale „zahrané s různou dynamikou“ mi zní divně?. Jejich vizuální rozdíl částečně odpovídá i rozdílu v barvě tónu, první tón má příjemný, měkký zvuk; druhý je výraznější a hrubší. Třetí tón se od zbylých liší svou výškou, což lze pozorovat na kratší periodě signálu, která je na obrázku vyznačená úsečkami.



Obrázek 1.3: Zvuk klarinetu, absolutní hodnota výstupu Fourierovy transformace signálu délky 4096 s oknem typu Hamming.

Jedním ze způsobů analýzy zvukového signálu je pomocí Fourierovy transformace (DFT). Základní myšlenkou je, že na signál lze hledět jako na vážený součet jednodušších signálů. Podobně, jako když se barvy na obrazovce míchají ze tří základních, libovolný zvuk můžeme smíchat ze sady sinusoid. Na obrázku 1.3 vidíme mnohem uchopitelnější reprezentaci zkoumaných zvuků klarinetu. Jednou z výhod této spektrální reprezentace je na první pohled zřejmý vztah frekvencí porovnávaných signálů, který odpovídá lidské intuici o výšce zvuků — tón E4 je na obrázku 1.3 opravdu „výš“ než tón A3. To zásadní, co ale spektrum tónu ukazuje, je jeho podstata jakožto součet *harmonických složek*.

Tón, kterému posluchač přisoudí výšku f_0 , se zpravidla skládá ze součtu sinusoid, jejichž frekvence je celočíselným násobkem základní frekvence f_0 . Například tedy tón A3 na obrázku 1.3 se skládá z frekvencí 220 Hz, 440 Hz, 660 Hz, ..., zároveň intenzita těchto harmonických frekvencí určuje barvu hlasu. Jak si můžeme všimnout na spektru, vyšší harmonické jsou u tónu hraném fortissimo mnohem výraznější než u tónu hraném pianissimo. **a tohle se dá říct? Tón hraný fortissimo/pianissimo. Moje znalosti hudební terminologie jsou nulové**

Tato harmonická struktura, která je vlastní téměř všem zvukům hudebních nástrojů i lidskému hlasu, je zásadní pro metody extrakce melodie. Je to vlastnost, která zvuky potenciálně nesoucí melodii odlišuje například od bubnového doprovodu nebo od šumu. Díky ní se také můžeme pokoušet rozložit souzvuk různě vysokých tónů na jejich původní, čisté signály.

spektrogram hudby - basa, zpěv a bubny. Pod tím obrázek kompletního přepisu melodických kontur

Obrázek 1.4: lorem ipsum

Nyní, po objevení podstaty zvuků, jimž lze přiřknout výšku, můžeme přejít k jejich hledání v hudební nahrávce. Obrázek 1.4 vznikl pomocí opakované Fourierovy transformace, která byla aplikována na po sobě jdoucí, krátké časové úseky vstupní nahrávky, přičemž intenzity frekvenčních složek v každém časovém okamžiku zvuku jsou nyní znázorněny odstínem barvy. Tuto časově-frekvenční reprezentaci signálu nazýváme *spektrogram*, a jeho výpočet je prvním krokem většiny metod pro extrakci melodie.

Abychom

1.1 Definice melodie

Rozpoznání melodie hrající skladby je pro většinu posluchačů intuitivní schopností, která je součástí prožitku poslechu hudby, a která jejímu poslechu vůbec dává smysl. Slyšet hudbu a nevnímat melodii je podobné jako poslouchat řeč a nerozumět větám. Ačkoli je melodie tedy termín, který je subjektivně jasný, formální, obecně přijímanou muzikologickou definici, která by se zpětně neodkazovala k posluchači, nemá.

Z tohoto důvodu si výzkumné týmy zabývající se automatickou transkripcí melodie volí pragmaticky spíše užší definice melodie, se kterými se v jejich kontextu lépe pracuje. Práce Goto a Hayamizu (1999), která je považována za jednu z prvních a důležitých prací v oboru, chápe melodii jako konturu fundamentální frekvence sestávající se z nejsilnějších tónů hrajících v omezeném frekvenčním rozsahu. Tato definice je poměrně úzká, tóny melodie se totiž jistě mohou vyskytovat i mimo autory specifikovaný rozsah a nemusí být vždy v poměru s doprovodem nejsilnější složkou signálu. Z technického hlediska však umožnila autorům implementaci algoritmu běžícího v reálném čase, který poskytoval sémanticky bohatý popis vstupních nahrávek. Navazující články pracují s volnějšími definicemi, které lépe reflektují podstatu melodie. Mimo to se používaná definice proměňuje díky novým datasetům, jejichž autoři tvoří protipól k ryze technickým a objektivním cílům algoritmických metod. Zatímco pro tvorbu algoritmů je praktické zvolit co nejkonkrétnější cíl, při tvorbě datasetu se naopak projevuje lidská subjektivita autorů anotací.

Kompromisem mezi subjektivní a praktickou definicí se na dlouhou dobu stala „extrakce základní frekvence hlavního melodického hlasu“. Ačkoli melodii v reálném hudebním materiálu obvykle nese více hlasů, které se v hraní střídají (například píseň se zpěvem a kytarovým sólem), v letech 2005 – 2015 se v soutěži MIREX provádí evaluace pouze nad krátkými výňatky, kde tato definice není omezující. Tento pohled však otevírá také jiné přístupy, například extrakci melodie pomocí modelování hudebního záznamu jako součtu signálu jednoho hlasu a doprovodu (Durrieu a David, 2010), (Bosch a Gómez, 2016) nebo přímo omezení se na separaci lidského zpěvu a doprovodu (Ikemiya a kol., 2016). Nově se objevují práce, které „hlavní“ melodický hlas neinterpretují nutně jako „nejsilnější“. Skladatelé a hráči používají množství různých postupů, které melodii zvýrazňují

— krom dynamiky ji ovlivňuje například také barva hlasu, vibrato nebo délka not. Salamon a Gomez (2012) využívá těchto rysů pro výběr mezi kandidáty na melodickou konturu.

Posunem v rámci MIR komunity bylo zveřejnění nových datasetů MedleyDB (Bittner a kol., 2014) a ORCHSET (Bosch a kol., 2016), oba přináší nová data, ve kterých již melodii nenese pouze jeden hlas po celou dobu skladby. V porovnání s do té doby dostupnými daty jde o mnohem rozmanitější kolekce. V případě MedleyDB jde o první volně dostupný dataset, ve kterém se objevují celé skladby, nikoli pouze výňatky a autoři předkládají rovnou tři verze anotací:

1. Základní frekvence nejvýraznějšího melodického hlasu, jehož zdroj zůstává po dobu nahrávky neměnný.
2. Základní frekvence nejvýraznějšího melodického hlasu, jehož zdroje se mohou měnit.
3. Základní frekvence všech melodických hlasů, potenciálně pocházejících z více zdrojů.

První formulace je v souladu s doposud používanou definicí. Zbylé dvě se snaží posouvat možné cíle budoucích metod a předložit komunitě nové výzvy, podle Salamon a kol. (2014) totiž výzkum začal v letech 2009–2012 stagnovat. Zatímco anotace s jednou melodickou linkou (1. a 2. definice) se v navazujících pracích často používají, zatím žádný článek se nepokusil představit metodu, jejímž cílem by bylo extrahovat více melodických linek (3. definice).

Bosch a kol. (2016) při práci na datasetu ORCHSET vychází z článku Poliner a kol. (2007), který definuje melodii jako „jednohlasou sekvenci tónů, kterou bude posluchač nejspíše reprodukovat, pokud jej požádáme o zapískání či zabroukání příslušné skladby“. Přestože nejde o objektivní definici, v praxi se posluchači často na jedné konkrétní sekvenci tónů shodnou, a to jak u populární hudby, kde melodii často nese lidský zpěv, tak u orchestrálních skladeb. Ačkoli se definice neujala pro metody extrakce, Bosch a kol. (2016) ji využili pro anotaci výňatků z orchestrálních skladeb, u kterých by předchozí zmíněné definice selhávaly, jelikož pojem melodie je u orchestrální hudby mnohdy komplikovanější než u jiných žánrů. Anotace tak spočívala v přezpívání orchestrálních výňatků skupinou posluchačů a následném srovnání a zpracování těchto nahrávek.

2. Související práce

Pokusy o vytvoření automatické metody pro kompletní transkripci hudby se podle Poliner a kol. (2007) objevují již od sedmdesátých let, z důvodu značné obtížnosti této úlohy, která strmě roste s každým dalším přidaným hlasem ve zkoumaném signálu, však dodnes jedná o otevřený problém. Z tohoto důvodu se od devadesátých let objevují práce, které se pokouší alespoň o částečný automatický popis některých muzikálních aspektů skladeb.

Jednou z prvních je práce týmu Goto a Hayamizu (1999), který se záměrně omezuje na identifikaci jedné, nejhlasitější, spojitě křivky fundamentní frekvence hlasu (F0) v omezeném frekvenčním rozsahu. Vzniklé transkripce pak sice nejsou kompletní, na druhou stranu je jejich získání výpočetně nenáročné a přitom poskytují sémanticky bohatý popis nahrávek, který je poměrně často shodný s melodií. Ustanovením úlohy pojmenované jako "Predominant-F0 Estimation" (PreFEst), byly položeny základy pro vznik navazujících prací a soutěží zabývajících se automatickým přepisem melodie.

Největší rozkvět v oboru začal od roku 2004. Uspořádáním první soutěže pro porovnání systémů pro automatický popis hudby v rámci konference ISMIR (ISMIR 2004 Audio Description Contest), se ustanovily priority, formalizovaly podmínky evaluace a byly sestaveny první kolekce dat pro testování algoritmů (Downie a kol. (2010)). Soutěž se v následujícím roku přerodila do samostatné každoroční události, v níž soutěží stále více týmů v rostoucím počtu úloh.

TODO: dopsat signpost

2.1 Průzkum existujících metod

Jen do soutěže MIREX se od roku 2005 přihlásilo 45 týmů s 62 různými metodami pro extrakci melodie, s různou mírou přesnosti přepisu. Mezi přístupy k tomuto problému tedy existuje velká rozmanitost, jejíž kompletní popis přesahuje rámec této práce. Zaměříme se proto na společné rysy a celkové trendy v oboru.

Shrnující práce od Poliner a kol. (2007) a Salamon a kol. (2014) se při charakterizaci systémů pro transkripci odkazují na příbuznou úlohu odhadu fundamentální frekvence monofonní nahrávky. Algoritmy pro monofonní tracking na základě vstupního signálu $x_{mono}(t)$ počítají *funkci salience* $S_{x_{mono}}(f_\tau, \tau)$ pro každý krátký časový okamžik (okno) τ a frekvenci f_τ . Výsledkem této funkce je relativní ohodnocení (příp. pravděpodobnost) jednotlivých frekvencí obsažených ve vstupním signálu, které značí, zda-li je daná frekvence fundamentální frekvencí znějícího hlasu.

Pro zvýšení robustnosti vůči šumu, přeslechu, dozvuku a jiným vlivům, které zhoršují kvalitu odhadu salience, se využívá také spojitosti fundamentální frekvence. Pro zajištění kontinuity extrahovaných frekvenčních kontur se zohledňuje také faktor temporálních závislostí $C(\mathbf{f})$, jejímž vstupem je kandidátní kontura \mathbf{f} a výstupem je ohodnocení této celé kontury na její spojitost. Například tato funkce může penalizovat odhady, ve kterých výstupní F0 často přeskakuje o oktavu, což je u skutečného signálu nepravděpodobné a naopak jde o častou chybu při výpočtu salienční funkce signálů se silnými sudými harmonickými frekvencemi.

Výstupem monofonního trackingu je posloupnost frekvencí s maximální salience a spojitostí, tedy posloupnost frekvencí, které jsou nejlépe ohodnocenými kandidáty na fundamentální frekvenci a zároveň tato celá sekvence má také vysoké ohodnocení spojitosti.

$$\hat{\mathbf{f}} = \operatorname{argmax}_{\mathbf{f}} \left[\sum_{\tau} S_{x_{mono}}(f_{\tau}, \tau) + C(\mathbf{f}) \right]$$

Přejdeme-li k úloze extrakce melodie, obecně se vstupní polyfonní signál $x(t) = x_m(t) + x_d(t)$ skládá ze směsi melodického hlasu $x_m(t)$ a hudebního doprovodu $x_d(t)$, cílem metod pro extrakci je z pohledu přepisu fundamentální frekvence zvýšení robustnosti algoritmu vůči mnohem výraznějšímu druhu šumu - hudebnímu doprovodu $x_d(t)$. Výstupem našeho systému tedy bude posloupnost odhadů frekvence v každém časovém okně vstupního signálu, reprezentovaná vektorem $\hat{\mathbf{f}}$:

$$\hat{\mathbf{f}} = \operatorname{argmax}_{\mathbf{f}} \left[\sum_{\tau} S'_x(f_{\tau}, \tau) + C'(\mathbf{f}) \right]$$

kde f_{τ} je frekvence na pozici τ ve vektoru \mathbf{f} . $S'_x(f_{\tau}, \tau)$ je upravená funkce salience, která při výpočtu zohledňuje vliv doprovodu a složka $C'(\mathbf{f})$ představuje ohodnocení celého průběhu melodie.

Spolu s odhadem frekvencí by také měl systém na výstupu určit úseky, ve kterých v nahrávce melodie zní a kdy nikoli. K výstupu tedy patří také vektor $\hat{\mathbf{v}}$, se stejným počtem složek jako $\hat{\mathbf{f}}$, který indikuje přítomnost melodie v každém časovém okně τ .

Většina existujících metod sdílí podobnou základní strukturu při řešení extrakce, která se zakládá na popsané formalizaci. Prvním krokem je transformace zvuku do frekvenční domény a následný odhad znějících výšek tónů v polyfonním signálu (výpočet *funkce salience*), druhým krokem je pak zpracování těchto odhadů a výběr melodie (tedy zpřesnění výsledné $\hat{\mathbf{f}}$ pomocí $C'(\mathbf{f})$). Přístupy k řešení těchto dvou kroků již s konkrétními příklady nastíníme v dalších sekcích.

2.1.1 Spektrální analýza

Zvuk hraného tónu na melodickém nástroji je z fyzikálního pohledu periodická změna tlaku vzduchu. Perioda tohoto signálu se nazývá fundamentální frekvence (označujeme F_0) a zpravidla je tento signál složen ze součtu řady sinusoid, jejichž frekvence jsou celočíselným násobkem fundamentální frekvence. V čase měnící se amplitudy těchto *harmonických frekvencí* udávají hlasitost a barvu hlasu, výška první harmonické frekvence (tj. výška fundamentální frekvence) pak ve většině případů odpovídá posluchačem vnímané výšce tónu.

TODO obrázek: signál -> spektrum -> salience

Prvním krokem metod pracujících s hudebním signálem je proto provedení spektrální analýzy, jde o převod zvuku do frekvenční reprezentace, která odhaluje tyto harmonické struktury tónů a umožňuje s nimi dále pracovat.

Krátkodobá Fourierova transformace

Přístupů ke spektrální analýze je více, přímočará a podle Dressler (2016) nejčastěji používaná metoda je *krátkodobá Fourierova transformace* (STFT). Jejím principem je rozdělení vstupního signálu na množinu překrývajících se oken

konstantní délky a výpočet Fourierovy transformace těchto krátkých zvukových úseků. Komplexní výsledek transformace umocníme a získáme tzv. výkonové spektrum signálu, které obsahuje informaci o poměrech energie frekvencí, ze kterých se signál v okně skládá.

$$X(f, \tau) = \int_{-W/2}^{W/2} w(t)y(\tau + t)e^{-j2\pi ft} dt$$

TODO vysvětlit vzoreček, minimálně písmena

Multirezoluční transformace

Na libovolnou metodu převodu diskretizovaného signálu na frekvenční doménu se vztahuje Gaborův limit, který popisuje závislost přesnosti lokalizace signálu ve frekvenční a časové doméně (Gabor a Member, 1945). Volbou délky vstupního okna transformace zpřesňujeme buď frekvenční nebo časové rozlišení výsledné spektrální reprezentace. Zvolíme-li krátké vstupní okno, zvyšujeme časové rozlišení (krátké okno lépe zachycuje rychlé změny průběhu signálu), avšak ztrácíme přesnost na frekvenční ose, opačný vztah platí pro volbu delšího okna.

Tato limitace je markantní zejména pokud STFT používáme pro hudební data. Z povahy hudebních intervalů a harmonických struktur tónů platí, že téměř všechny periodické signály se v hudební skladbě vyskytují ve vzájemných poměrech (v případě intervalů v poměrech $2^{\frac{n}{12}}$ a v případě harmonických frekvencí v celočíselných), u vyšších tónů jsou proto vzdálenosti mezi frekvencemi signálů větší než u nižších tónů. Frekvenční rozlišení STFT je však konstantní na celém výstupním frekvenčním rozsahu a volba velikosti okna transformace zajistí dobrý poměr frekvenčního a časového rozlišení jen pro část rozsahu. Ve výsledku je pak buď pro vyšší frekvence okno příliš velké (zbytečně detailní frekvenční rozlišení na úkor časového rozlišení) a nebo naopak pro nižší frekvence je okno nedostačující (rozlišení frekvence nemusí být pro basy ani na úrovni půltónů).

Z tohoto důvodu existují vedle STFT i další metody, jejichž cílem je nabídnout lepší kompromis frekvenčně-časového rozlišení v kontextu melodických dat. Goto a Hayamizu (1999) používají MRFFT (Multi-Resolution Fast Fourier Transform), principem je opakovaný downsampling signálu (převzorkování na nižší vzorkovací frekvenci) a aplikace Fourierovy transformace na každý vzniklý signál; s každou iterací spektrum obsahuje čím dál podrobnější informace o nižších frekvencích, protože vyšší frekvence se při downsamplingu ztratí. Brown (1990) popsala metodu Constant-Q Transform (CQT), která spočívá v použití proměnné délky okna Fourierovy transformace pro výstupní frekvenční pásma, která rovnoměrně pokrývají logaritmickou osu frekvence. Paiva a kol. (2004) napodobují mechanismy lidského sluchu pomocí banky pásmových filtrů (Cochleagram) s logaritmicky rozmístěnými mezními frekvencemi a sumy autokorelací na jednotlivých frekvenčních pásmech signálu (Summary correlogram).

I přes uvedené důvody se Salamon a kol. (2014) a Dressler (2016) domnívají, že metoda zpracování signálu příliš neovlivňuje výslednou přesnost algoritmů pro přepis melodie. Tvrzení dokládají jednak celkovým srovnáním výsledků metod ze všech ročníků soutěže MIREX a jednak neochvějnou převahou využití krátkodobé Fourierovy transformace, jakožto efektivní a dostačující metody pro spektrální analýzu.

Postprocessing spektrogramu

Po převodu signálu na frekvenční reprezentaci následuje u většiny metod některý druh úpravy celého spektrogramu, předcházející samotnému výpočtu *funkce salience*. Výsledkem tohoto kroku může být potlačení šumu a nemelodických částí signálu, zpřesnění informace o výšce znějících frekvencí nebo normalizace či jiná úprava amplitud spektrogramu.

Nejčastější úpravou je nalezení lokálních maxim (vrcholů). Potlačením ne-maximálních oblastí se zbavíme velkého množství nemelodických složek signálu, přitom informaci o těch melodických neztratíme. Výhodou práce s množinou vrcholů je, že jejich frekvenci lze na základě spektra dále zpřesnit pomocí parabolické interpolace (Rao a Rao (2010)) a nebo využitím úhlové frekvence (Salamon a Gomez (2012), Dressler (2009)).

Jiným druhem úpravy jsou různé způsoby normalizace, ať jednoduché aplikace logaritmu na jednotlivé hodnoty spektrogramu (Cancela (2008), Bittner a kol. (2017)) nebo složitější strategie normalizace, které se aplikují na celá výstupní okna krátkodobé Fourierovy transformace (spectral whitening, Ryyänen a Klappuri (2008)), či které používají pohyblivé průměry nebo jinou metodu, beroucí v potaz širší zvukový kontext. Cílem normalizace je zvýraznění slabších harmonických frekvencí a potlačení celopásmových zvuků (například perkusí). Principiálně podobným krokem je aplikace pásmového filtru (Goto a Hayamizu (1999)) pro zvýraznění frekvencí obsahující melodii. Případně využití psychoakustických filtrů modelující lidské vnímání hlasitosti (Salamon a Gomez (2012), Ikemiya a kol. (2016)). Ze signálu lze také oddělit melodické nástroje a perkusivní doprovod pomocí metod separace signálů (*source separation*). Používanými metodami jsou například Harmonic/Percussive Sound Separation (HPSS) (Tachibana a kol. (2010)) nebo Robust principal component analysis (RPCA) (Ikemiya a kol. (2016)).

2.1.2 Funkce salience

Salience tónu vyjadřuje míru důležitosti či nápadnosti ke svému hudebnímu okolí. Nejvíce ji ovlivňuje hlasitost v poměru ke zbylým znějícím hlasům, vliv má ale také řada dalších charakteristik hraní. Dressler (2016) mezi příklady uvádí například frekvenční modulaci, jako je vibrato nebo glissando, zejména oproti frekvenčně stálému hudebnímu doprovodu (piano, kytara). Velký vliv má samozřejmě také i barva hlasu. Lidský zpěv nebo obecně zvuky se silnějšími vyššími alikvótními frekvencemi snadněji upoutají pozornost. V případě vícehlasu mají obecně posluchači potíže rozeznat výšky tónů uvnitř souzvuku. Pokud má posluchač přiřadit pocíťovanou výšku tónu akordu, obvykle volí nejvyšší či nejnižší ze znějících frekvencí.

Výstupem *funkce salience* je ohodnocení každé výšky tónu v každém časovém okamžiku nahrávky, které co nejlépe odpovídá v relativních poměrech výše popsané zvukové salience. Jelikož neexistují žádné studie, které by se zabývaly měřením a kvantifikací salience v hudbě, nelze posoudit, jak dobře výsledky obvyklých způsobů výpočtu funkce salience korelují s mírou, ze které vychází. Bittner (2018) se však domnívá, že odhad bude velmi hrubý, většina postupů totiž do výpočtu zahrnuje pouze hlasitost hlasu, a tedy vynechává řadu jiných důležitých faktorů, které salience ovlivňují.

Přístupy k výpočtu by se daly zařadit do tří kategorií - sčítání harmonických frekvencí, odhad parametrů modelujících vstup a metody strojového učení.

Sčítání harmonických frekvencí

TODO: obrázek salience pomocí harmonické sumy

Metody založené na sčítání harmonických frekvencí jsou principiálně nejjednodušší skupinou. Vychází z práce Hermes (1988), jejich podstatou je využití harmonické struktury zvuku tónů. Ohodnocení frekvence f_τ získáme váženou sumou amplitud všech jejích harmonických frekvencí $h \cdot f_\tau$. Pro spektrogram $X(f, \tau)$ signálu x , funkci vah $g(f_\tau, h)$ a N_h počet zahrnutých harmonických frekvencí v sumě:

$$S_x(f_\tau, \tau) = \sum_{h=1}^{N_h} g(f_\tau, h) |X(h \cdot f, \tau)|$$

Pro ilustraci uvažme jednohlasý harmonický signál s fundamentální frekvencí f^* . Hodnoty spektrogramu $X(f, \tau)$ tedy budou vyšší kolem frekvencí $H_{f^*} = \{1 \cdot f^*, 2 \cdot f^*, 3 \cdot f^*, \dots\}$ a jinde nulové. Funkce $S_x(f, \tau)$ bude tedy pro $f \notin H_{f^*}$ nulová a v f^* bude nabývat globálního maxima.

Dressler (2011) tuto metodu vylepšuje zpracováváním dvojic vrcholů vstupního spektrogramu, její výsledný salienční spektrogram obsahuje méně kandidátů na fundamentální frekvenci. Cancela (2008) se pokouší zmenšovat chybné hodnoty salienční funkce pomocí vyhodnocení subharmonických frekvencí.

Statistické modelování signálu

TODO: obrázek salience pomocí modelů tónů

Jiným přístupem k počítání *funkce salience*, který používá Goto a Hayamizu (1999), je modelování okna spektrogramu váženým součtem harmonických struktur (modelů tónů). Snažíme se vrcholy ve spektru rozdělit mezi různě silně znějící tóny tak, aby v součtu co nejlépe odpovídaly měřeným intenzitám. Přístup se jinými slovy snaží zjistit, jaké tóny musely v danou chvíli znít, aby vzniklo dané spektrum.

Vstupem metody je okno normalizovaného spektrogramu $p_X^{(t)}(x)$ v čase t . Okno se pokusíme modelovat jako hustotu pravděpodobnosti $p(x; \theta^{(t)})$ vzniklou váženou směsí modelů všech možných tónů melodie v definovaném rozsahu frekvencí v intervalu $[F_l, F_h]$. Hustotu pravděpodobnosti jednoho z tónů s fundamentální frekvencí F označíme jako $p(x|F)$, a jako $w^{(t)}(F)$ označíme váhu, kterou model tónu $p(x|F)$ přispívá do celkové smíšené hustoty pravděpodobnosti. Pak $p(x; \theta^{(t)})$ definujeme jako:

$$p(x; \theta^{(t)}) = \int_{F_l}^{F_h} w^{(t)}(F) p(x|F) dF$$

$$\theta^{(t)} = \{ w^{(t)}(F) \mid F_l < F < F_h \}$$

Cílem pak je nalezení takových parametrů $\theta^{(t)}$, aby model $p(x; \theta^{(t)})$ dobře popisoval pozorování $p_X^{(t)}(x)$. K tomu Goto a Hayamizu (1999) využívá Expectation-Maximization (EM) algoritmus. Výsledné parametry $\theta^{(t)}$ jsou pak hodnoty salienční funkce.

TODO: popsat Durrieu, jakožto jiný přístup k modelování signálu

Metody strojového učení

TODO

Metody strojového učení

2.1.3 Hledání melodie

TODO: tady bude popis tone trackingu různých metod, asi nemusí být tak rozsáhlý, jelikož moje práce se tím nejspíš nestihne zabývat TODO: píšu to unaveně, kdyžtak přepsat

Po výpočtu funkce salience $S_x(f_\tau, \tau)$ máme k dispozici odhady fundamentálních frekvencí v signálu, z těchto ohodnocení pak musíme vybrat výslednou konturu melodie. Triviálním řešením by bylo vybrat frekvence s maximální salience pro každé časové okno $\hat{f}_\tau = \operatorname{argmax}_{f_\tau} S_x(f_\tau, \tau)$, tento jednoduchý přístup však nevolí mnoho metod.

Přítomnost melodie (voicing)

2.2 Srovnání existujících metod

Pro celkové kvantitativní srovnání metod jsme zpracovali výsledky všech ročníků soutěže MIREX a dostupné, state-of-the-art metody spustili na dalších datech, která do vyhodnocování v soutěži MIREX nejsou zahrnuta. Výsledkem je podrobné srovnání většiny relevantních, existujících metod pro extrakci melodie.

TODO: tabulka metod s popisem architektury TODO: tabulka metod s výsledky v mirexu a na mých datech

3. Datasets

Nedostupnost dostatečného množství dat pro automatickou transkripci melodie představuje zejména pro metody strojového učení otevřený problém. Zatímco pro vzdáleně příbuznou úlohu automatického přepisu mluveného slova existuje tisíce hodin nahrávek (například dataset LibriSpeech, který vznikl na základě audioknih), největší dataset s přepsanou melodickou linkou MedleyDB má celkovou délku pod osm hodin. Do roku 2014, kdy MedleyDB vznikl, existovaly datasety, které byly buď rozmanité, ale příliš krátké (ADC04, MIREX05, INDIAN08) nebo naopak celkově větší, ale žánrově a hudebně homogenní (MIREX09, MIR1K, RWC). V roce 2015 byl vydán dataset Orchset, který obsahuje 23 minut výňatků z orchestrálních skladeb různých období. Za dataset pro extrakci melodie se také dá považovat Weimar Jazz Database, který je sice primárně zaměřený na využití v muzikologii, nicméně obsahuje přes 450 přepsaných jazzových sól. Novinkou z roku 2017 je vydání datasetu MDB-melody-synth, který byl automaticky vygenerován základě vstupní vícestopé hudby (převzaté z MedleyDB), existuje tedy naděje, že současný korpus pro přepis melodie by se mohl v budoucnu rozšířit o velkou část automaticky přesyntetizovaných, veřejně dostupných vícestopých nahrávek.

Co se týče blízké úlohy transkripce hudby, velikost největších datasetů se pohybuje v řádu desítek hodin, tudíž jde stále o omezené kolekce. Mezi největší se řadí MusicNet (orchestrální, 34 hodin), MAPS (klavír, 18 hodin), MDB-mf0-synth (multižánrový, 4,7 hodin), GuitarSet (kytara, 3 hodiny) a URMP (komorní orchestr, 1,3 hodiny). I když jde o úlohu, která je lépe definovaná (na rozdíl od extrakce melodie zde nehraje roli subjektivita volby hlavního hlasu), s použitím polyfonních nástrojů vyvstává problém náročné ruční anotace.

Vytváření nových datasetů je obecně velmi pracné a nákladné. Obvyklý postup totiž zahrnuje buď kompletní ruční přepis nahrávky nebo alespoň ruční opravu výstupu automatického přepisu, přičemž tuto práci odvedou kvalitně pouze zaškolení hudebníci. Každá vzniklá anotace se také musí překontrolovat, a to nejlépe jiným hudebníkem. Dalším problémem je vůbec identifikace melodie - jelikož je určení hlavní melodické linie subjektivní, musí se na výsledné anotaci shodnout co nejvíce posluchači. Ve výsledku se proto do datasetů buď vybírají takové nahrávky, které nejsou sporné, nebo na každé anotaci pracuje celý tým, který melodii společně určí. S tím souvisí také zavedení a pečlivé dodržování anotační politiky u komplexnějších skladeb (zejména orchestrálních), kde může melodii nést více hlasů zároveň (současně či střídajíc se). Také množství výchozích dat pro vznik datasetů není velké. Jednak musí být skladby šiřitelné, pokud má být dataset volně dostupný a jednak by k nim měly být dostupné audiostopy, ze kterých je smíchán finální mix, jelikož ruční anotace finálního mixu je mnohem náročnější než anotace oddělených stop.

Existence dostatečně velkých datasetů je obecně vzato zásadním předpokladem pro využití metod strojového učení pomocí hlubokých neuronových sítí, zejména pak pro netriviální úlohy, jakou je například přepis melodie, jelikož dovoluje zvětšení celkové kapacity modelu, aniž by docházelo k overfittingu. Také pro evaluaci metod, například i v soutěži MIREX, jsou potřeba takové datasety, které dobře reprezentují reálná data, přitom dataset MedleyDB vznikl mimo jiné

z důvodu, že stávající datasety nestačily ani pro účel evaluace.

Napsat signpost

3.1 Struktura dostupných dat a jejich přehled

TODO: Motivační obrázek pianoroll a zarovnaného audia TODO: Do struktury dat přidat screenshot/vizuálně oddělený výňatek csv souboru s anotacemi. Musí tam být nuly, negativní a pozitivní frekvence

	MedleyDB	Orchset
mix audio	Y	Y
stem audio	Y **	N
Multi f0	*	N
MIDI	N	N
Stem MIDI	N	N
Stem priority	Y	N
Melody f0	Y	N
Melody MIDI	N	Y
Hours of audio	7.3***	23.4m
Voiced frames	60.9%	93.69%
Number of tracks	122***	64
Webová stránka	https://medleydb.weebly.com/	https://www.upf.edu/web/mtg/orc
Žánr	Mnohožánrový	Orchestrální

Tabulka 3.1: Souhrnná tabulka se základními informacemi o veřejně dostupných datasetech.

* pouze monofonní nástroje, pouze melodie (tj. doprovod není anotován) ** část stemů s větším či menším bleedem (toto je anotované) *** 5.59h s anotací, 108 tracků **** neveřejné, ale autoři poskytují pro výzkumné účely ***** hlas a doprovod

pěkný podobný seznam datasetů: <https://arxiv.org/pdf/1612.08727.pdf>

TODO: Tabulka splitů a použití v práci TODO: Tabulka datasetů v MIREXu

3.2 MedleyDB

Bittner a kol. (2014)

Multimodální, vícestopý dataset obsahující 122 nahrávek, k 108 z nich je dostupná anotace melodie. Kromě té dataset obsahuje také metadata o všech písních s informacemi o žánru a instrumentalizaci. S celkovou délkou 7.3 hodiny jde o nejdelší dataset, který se zaměřuje na více hudebních žánrů. O rozmanitosti svědčí i to, že se v datasetu vyskytuje řada nástrojů mimoevropského původu, a že jen přibližně polovina písní obsahuje zpěv. Na rozdíl od ostatních datasetů jsou nahrávky ve většině případů celé písně, tedy nejde pouze o krátké výňatky, a ke každé jsou poskytnuty audiostopy, ze kterých je vytvořen výsledný mix. Na základě diskuze, kterou shrnuji v kapitole o definici melodie, autoři poskytují tři verze anotací, na základě různě obecných definic:

1. Základní frekvence nejvýraznějšího melodického hlasu, jehož zdroj zůstává po dobu nahrávky neměnný.¹
2. Základní frekvence nejvýraznějšího melodického hlasu, jehož zdroje se mohou měnit.
3. Základní frekvence všech melodických hlasů, potenciálně pocházejících z více zdrojů.

Ačkoli třetí definice umožňuje, aby v anotaci znělo více melodických linek zároveň, v datasetu se nejedná o kompletní přepis nahrávek (použitelný pro úlohu *multif0 estimation*), ten autoři neposkytují.

Dataset vznikl obvyklou cestou ruční anotace, ze shromážděného vícestopého materiálu byly vybrány stopy s potenciálním výskytem melodie, stopy s přeslechem byly filtrovány pomocí source-separation algoritmu s ručně doladěnými parametry pro každou jednotlivou stopu, následně byl na monofonní stopy spuštěn pitch-tracker pYIN a výsledné automaticky získané anotace opravilo a vzájemně zkontrolovalo pět anotátorů s hudebním vzděláním.

3.3 MDB-synth

Hlavním přínosem práce Salamon a kol. (2017) je navržení způsobu anotace základní frekvence monofonních audiostop takovým způsobem, že výsledná dvojice zvukové stopy a anotace nevyžaduje další manuální kontrolu. Anotace stopy probíhá ve dvou krocích, nejprve získáme pomocí libovolného monopitch trackeru křivku základní frekvence a poté na základě této křivky, která může obsahovat chybné úseky, syntetizujeme novou stopu, která zachovává barvu nahrávky, ale výšku tónu určuje právě tato anotace. Díky tomu je pak přesnost anotace pro tuto novou, syntetickou nahrávku stop procentní, přitom (v ideálním případě) neztrácí charakteristiky původní nahrávky.

Pro vytváření datasetu je toto významné zjednodušení, protože tím algoritmus odstraňuje časově nejnáročnější část práce - ruční kontrolu anotací audiostop. Pokud by se ukázalo, že syntéza významně neubírá na kvalitě dat, použitím navrhované metody by mohlo vzniknout velké množství nových dat (například repozitář Open Multitrack Testbed obsahuje stovky vícestopých nahrávek, které by šlo využít). Autoři v článku provádí kvantitativní analýzu pomocí srovnání state-of-the-art algoritmů pro extrakci melodie a prokazují, že výsledky těchto metod na syntetických datech se významně neliší od výsledků na původních, tím je podle autorů potvrzená možnost použití dat jak pro trénování tak pro evaluaci nových metod.

Metoda má ale bohužel svá omezení, mezi ty zásadní patří, že se dá aplikovat pouze na stopy, které obsahují monofonní signál, vstupní data tedy nesmí obsahovat přeslech a nahrávaný nástroj může hrát pouze jednohlas, v důsledku nelze zpracovat klavír či kytara, které hrají zpravidla vícehlas. To nevadí tolik u generování datasetu pro přepis melodie, jelikož melodii často hraje jeden hlas a doprovod hrají ostatní, velkým nedostatkem je toto spíše pro generování multif0 datasetů.

¹Tato definice je shodná pro evaluační datasety používané v soutěži MIREX, s výjimkou Orchsetu

Dále k článku není zveřejněná kompletní referenční implementace algoritmu, tudíž algoritmus nelze snadno spustit na nových datech. Ve výsledku je tudíž největším praktickým přínosem nová sada syntetických datasetů pro úlohy přepisu melodie, basy, monofonních stop a kompletní partitury, každý dataset obsahuje destíky nahrávek. Vícestopá data použitá pro syntézu byla převzata z MedleyDB, tudíž ve výsledku nové datasety nerozšiřují celkový hudební záběr, pouze zpřesňují ten již existující.

TODO obrázek? Porovnání spektrogramů syntetické a původní nahrávky

Z kvalitativního pohledu je na výstupních syntetických nahrávkách poznat, že jsou syntetické. Autoři sice prokazují, že současné metody na těchto datech dosahují stejných výsledků, nicméně v článku chybí diskuse o tom, zda-li v datech algoritmus nevytváří nové umělé artefakty, které by mohly zneužít metody strojového učení pro spolehlivější výsledky (které by však negeneralizovaly na reálná data). Při pohledu na spektrogram je například zřejmé, že syntetická nahrávka obsahuje mnohem více výrazných alikvótních frekvencí

3.4 Orchset

Dataset vytvořený týmem Bosch a kol. (2016) orientovaný na orchestrální repertoár pocházející z různých historických období včetně 20. století. Obsahuje 64 výňatků délky od 10 do 32 sekund. Výňatky byly vybírány tak, aby obsahovaly zřejmou melodii, dataset tedy obsahuje v porovnání málo pasáží bez melodie (6% z celkové délky). Vzhledem k komplexitě uvažovaných žánrů autoři vycházejí z kombinace rozšířené definice melodie podle Bittner a kol. (2014) a definice Poliner a kol. (2007). Melodii ve výňatcích proto zpravidla nese více hudebních nástrojů (nebo celých sekcí), které se v průběhu střídají, případně mohou části hrát společně v rozdílných oktávách (nebo jiných intervalech, tvoříce tak harmonický doprovod).

Pro zjištění melodie se v takto vrstveném materiálu autoři uchylují k úplnému základu definice melodie (Poliner) a nechávají si skupinou čtyř posluchačů výňatky přezpívat. Tato hrubá data pak autoři sumarizují a odebírají z datasetu ty výňatky, na jejichž melodii se posluchači neshodli. Přezpívané tóny bylo nutné ručně opravit, aby načasováním přesně seděly na výňatek. Lidský hlas také samozřejmě nemá rozsah plného orchestru, proto bylo dalším krokem transponovat anotace tak, aby zněly ve správných oktávách. Zde se opět může vyskytnout problém subjektivity, pokud melodii hrají dva různé nástroje, pouze v jiných oktávách, pak je sporné, který nástroj označit jako hlavní (v některých případech taková otázka ani nedává příliš smysl.). Částečným řešením je zvolit libovolnou anotační politiku a tu konzistentně dodržovat (žádná společná v komunitě MIR neexistuje), v případě Orchsetu byla snaha minimalizovat skoky v melodické kontuře, což zároveň respektuje obecné pozorování, že v melodii se vyskytují mnohem častěji malé skoky (nejčastěji prima a malá/velká sekunda) než větší. Tedy například pokud pasáží hrané ve dvou různých oktávách předcházela pasáž hraná v jedné, anotace obou pasáží lze transponovat do společné oktávy tak, abychom na rozhraní minimalizovali skok v anotaci.

Dataset obsahuje pouze hrubé anotace tónů melodie, nikoli přesnou základní frekvenci nástroje, který v danou chvíli melodii hraje. Článek o tomto rozhodnutí příliš nediskutuje, vychází ale opět logicky z volby dat. U orchestrálních dat je

tento abstraktnější pojem melodie mnohem méně sporný. Pokud hraje melodii sekce nástrojů v unisonu, přesná základní frekvence není dobře definovaná, jelikož se základní frekvence znějících hlasů vzájemně překrývají.

3.5 Weimar Jazz Database

Weimar Jazz Database Pfeiderer a kol. obsahuje přes 450 transkripcí jazzových sól ze všech období vývoje jazzu. Data původně zamýšlená pro muzikologické studie využívající statistické metody ale lze využít i pro potřeby extrakce melodie, jelikož uvažované nahrávky spadají zřejmě pod nejrestriktivnější definici melodie (definici používanou v soutěži MIREX) - melodii nese jistě právě jeden, sólový nástroj, a po celou dobu výňatku je jistě nejvýraznější. Výběr sólových nástrojů se omezuje pouze na jednohlasé, jelikož ruční anotace vícehlasých je příliš obtížná. Hlavním problémem při využívání je restriktivní licence, která platí na nahrávky, tudíž zdrojové audio, na základě kterého anotace vznikaly, není veřejně přístupné. Jelikož pro data neexistují jednotlivé stopy, ruční anotace probíhala přímo z finální nahrávky, což je obtížný úkol -

4. Evaluace metod

4.1 MIREX

Soutěž MIREX (Music Information Retrieval Evaluation eXchange) probíhá již od roku 2005 a v MIR komunitě zastává hlavní postavení jakožto každoroční událost pro nezávislé, objektivní srovnání state-of-the-art metod a algoritmů pro řešení širokého spektra úloh souvisejících se zpracováním hudebních dat. Mezi tyto úlohy patří například *rozpoznání žánru*, *odhad tempa*, *odhad akordů*, *identifikace coveru* a samozřejmě také *extrakce melodie*.

Na rozdíl od jiných úloh, kde debata o zvolení nejvhodnějších objektivních metrik pro porovnávání stále probíhá, metriky pro extrakci melodie se ustano- vily již v prvním ročníku (na základě dřívějších zkušeností) a zůstaly neměnné dodnes Raffel a kol. (2014). Naopak data použitá pro testování se postupně ku- mulují a dnes soutěž probíhá již s řadou datasetů (ADC04, MIREX05, MIREX08, MIREX09, ORCHSET), které blíže popisuje kapitola o dostupných datech.

4.2 Trénovací, validační a testovací množina

Z dostupných dat, které pro úlohu máme k dispozici, musíme vyhradit mno- žiny pro trénování, validaci a testování, aby byly metody porovnatelné jak mezi sebou, tak se stávajícími state-of-the-art metodami. Pro trénování se jeví jako nejvhodnější dataset MedleyDB, jednak pro svou délku a jednak pro žánrovou rozmanitost, proto je použit pro většinu popsanych experimentů. Rozdělení na tři části vychází z práce Bittner a kol. (2017) a D Basaran, S Essid (2018), aby byly metriky přímo porovnatelné s výsledky v uvedených člancích.

Dalším užitečným zdrojem dat je dataset MDB-melody-synth, který je pře- syntetizován z vícestopých nahrávek MedleyDB. Proto se nabízí použít stejné rozdělení dat, jaké se používá pro MedleyDB, ze stejných důvodů uvedených v předchozím odstavci. Jelikož dataset neobsahuje veškerá data, ale pouze jejich podmnožinu, i v experimentech používané rozdělení dat obsahuje pouze podmno- žinu z původního rozdělení datasetu MedleyDB.

Posledním velkým datasetem, používaným pro trénování, je Weimar Jazz Da- tabase. Zde žádný doporučený postup ani výběr rozdělení dataestu v relevantní literatuře neexistuje, proto jsem dataset rozdělil podle metody Bittner a kol. (2017) na tři části (v celkové délce nahrávek na části v poměrech 63%, 14% a 23%). Skladby jsou rozděleny do částí podle interpretů tak, aby se každý in- terpret vyskytoval právě v jedné části datasetu. Toto omezení na podmnožiny Bittner a kol. (2017) nediskutuje, lze však doložit (práce Sturm (2013)), že pro úlohu rozpoznání žánru metody založené na strojovém učení vykazují po tré- nování a validaci na datech bez tohoto filtru výrazně lepší výsledky než stejné metody spuštěné na roztríděných datech, takové zlepšení výkonu je ale jistě umě- lým důsledkem špatné volby trénovací množiny.

Ostatní datasety (ADC04, MIREX05, ORCHSET) jsou v práci použity pouze jako testovací data, díky tomu lze korektně výsledky přímo srovnávat s žebříčky úlohy Melody Extraction v soutěži MIREX.

4.3 Kvalitativní příklady

Pro lepší porozumění hranic testovaných metod je vhodné studovat také výsledky na kvalitativních ukázkách. Modely byly při práci vyhodnocovány na několikaminutových množinách výňatků z validačních a testovacích dat. Metodika výběru spočívala v poslechu nahrávek a ručním hledáním zajímavých hudebních jevů a také v seřazení nahrávek podle úspěšnosti přepisu stávajícími metodami a výběrem výňatků právě z těchto nejproblematictějších příkladů.

Omezení plynoucí z potřeby zkrátit výňatky na minimum,

4.4 Metriky

Celkovou kvalitu metody pro extrakci melodie určuje její schopnost určit výšku tónu hrající melodie (*odhad výšky melodie*) a také rozpoznat části skladby, které melodii neobsahují (*detekce melodie*). Jelikož jsou tyto podúlohy na sobě nezávislé, standardní sada metrik zahrnuje jak celkové vyhodnocení přesnosti, tak dílčí vyhodnocení pro *odhad výšky* a *detekci melodie*.

4.4.1 Formát výstupu

Obvyklý formát výstupu algoritmů je CSV soubor se dvěma sloupci. První sloupec obsahuje pravidelné časové značky, druhý sloupec pak odhad základní frekvence melodie. Některé algoritmy uvádí i odhady výšky základní frekvence mimo detekovanou melodii (může jít například o doprovod, který zní i po hlavním melodickém hlasu). Aby tyto odhady byly odlišené od odhadů hlavní melodie, jsou uvedeny v záporných hodnotách. Díky tomu pak lze nezávisle vyhodnotit přesnost *odhadu výšky* a *detekce melodie*. Odhad výšky se vyhodnocuje podle absolutní hodnoty frekvence ve všech časových oknech, ke kterým existuje anotace, detekce melodie pak na všech hodnotách vyšších než 0.

4.4.2 Definice metrik

Většina metrik je definována na základě porovnávání jednotlivých anotačních oken - tedy typicky srovnáním odhadovaných a pravdivých výšek melodie po konstantních časových skocích. Datasets používané pro vyhodnocování v soutěži MIREX používají časový skok délky 10 ms. V definicích budu vycházet ze značení v práci Salamon a kol. (2014).

Označme vektor odhadovaných základních frekvencí \mathbf{f} a cílový vektor \mathbf{f}^* , složka f_τ je buď rovna hodnotě f_0 melodie, nebo 0, pokud v daném čase melodie nezní. Obdobně zavedme vektor indikátorů \mathbf{v} , jehož prvek na pozici τ je roven $v_\tau = 1$, pokud je v daném časovém okamžiku detekována melodie a $v_\tau = 0$ v opačném případě. Podobným způsobem zavedeme i vektor cílových indikátorů melodického hlasu \mathbf{v}^* a také vektor indikátorů absence melodie $\bar{v}_\tau = 1 - v_\tau$.

přidat obrázky příkladů chyby

Voicing Recall rate (Úplnost detekce)

Poměr počtu časových oken, které byly správně označené jakožto obsahující melodii, a počtu časových oken doopravdy obsahujících melodii podle anotace.

$$\text{VR}(\mathbf{v}, \mathbf{v}^*) = \frac{\sum_{\tau} v_{\tau} v_{\tau}^*}{\sum_{\tau} v_{\tau}^*}$$

Voicing False Alarm rate (Nesprávné detekce)

Poměr počtu časových oken, které byly nesprávně označené jako melodické, k počtu doopravdy nemelodických oken.

$$\text{FA}(\mathbf{v}, \mathbf{v}^*) = \frac{\sum_{\tau} v_{\tau} \bar{v}_{\tau}^*}{\sum_{\tau} \bar{v}_{\tau}^*}$$

upozornit, že nižší je lepší!

Raw Pitch Accuracy (Přesnost odhadu výšky)

Poměr správně odhadnutých tónů k celkovému počtu melodických oken. Výška správně určeného tónu se může lišit až o jeden půltón.

$$\text{RPA}(\mathbf{f}, \mathbf{f}^*) = \frac{\sum_{\tau} v_{\tau}^* v_{\tau} \mathcal{T}[\mathcal{M}(f_{\tau}) - \mathcal{M}(f_{\tau}^*)]}{\sum_{\tau} v_{\tau}^*}$$

kde \mathcal{T} je prahová funkce

$$\mathcal{T}[a] = \begin{cases} 1 & \text{pro } |a| \leq 0.5 \\ 0 & \text{jinak} \end{cases}$$

přidat zmínku o možnosti změnění práhu

a \mathcal{M} je funkce zobrazující frekvenci f na reálné číslo počtu půltónů od nějakého referenčního tónu f_{ref} (například od 440 Hz, tedy komorního A4).

$$\mathcal{M}(f) = 12 \log_2\left(\frac{f}{f_{\text{ref}}}\right)$$

Raw Chroma Accuracy (Přesnost odhadu výšky nezávisle na oktávě)

Počítá se podobně jako *Přesnost odhadu tónu*, výstupní a cílové tóny jsou však mapovány na společnou oktávu. Metrika tedy ignoruje chyby odhadu způsobené špatným určením oktávy tónu.

$$\text{RCA}(\mathbf{f}, \mathbf{f}^*) = \frac{\sum_{\tau} v_{\tau}^* v_{\tau} \mathcal{T}[\langle \mathcal{M}(f_{\tau}) - \mathcal{M}(f_{\tau}^*) \rangle_{12}]}{\sum_{\tau} v_{\tau}^*}$$

Nezávislost na oktávě zajistíme pomocí zobrazení rozdílu cílového a výstupního tónu na společnou oktávu.

$$\langle a \rangle_{12} = a - 12 \lfloor \frac{a}{12} + 0.5 \rfloor$$

Overall Accuracy (Celková přesnost)

Celková přesnost měří výkon algoritmu jak v odhadu melodie tak v detekci melodie. Počítá se jako podíl správně odhadnutých oken a celkového počtu oken.

$$\text{OA}(\mathbf{f}, \mathbf{f}^*) = \frac{\sum_{\tau} v_{\tau}^* v_{\tau} \mathcal{T}[\mathcal{M}(f_{\tau}) - \mathcal{M}(f_{\tau}^*)] + \bar{v}_{\tau}^* \bar{v}_{\tau}}{L}$$

Poznámka k definicím metrik

Definice RPA, RCA a OA zde uvedené se mírně liší od výchozích v práci Salamon a kol. (2014), jejich přímá implementace podle vzorce totiž vede kvůli nedostatečně dobře zadanému vektoru frekvencí \mathbf{f} k chybě, která se týká zejména metriky RCA. Ta původní definici chybně zahrnovala jako správné tóny ty, které algoritmus odhadl jako nulové (tedy neznějící) a zároveň jejich pravdivá hodnota byla po zobrazení na jednu společnou oktávu blízká nule (tedy původní tón byl blízký nějakému násobku referenční frekvence). Kvůli zobrazení na společnou oktávu se stanou „neznělé nulové odhady“ a tóny blízké referenčním frekvencím nerozlišitelné a byly nesprávně považované za korektní.¹

přepsat footnote ještě trochu

4.4.3 Další metriky

Protože princip vnitřního fungování neuronových sítí často není zřejmý, je užitečné mít co nejvíce různých indikátorů, abychom měli při porovnávání jednotlivých modelů alespoň podrobnou informaci, v jakých ohledech se síť zlepšuje nebo zhoršuje. Pro tento účel jsem při práci implementoval další metriky, které při hledání architektur sítí pomáhaly.

Chroma Overall Accuracy

Počítá se obdobně jako Overall Accuracy, ale tóny jsou mapovány na společnou oktávu.

Raw Harmonic Accuracy

Metrika počítá odhadovaný tón jako správný, pokud se trefil do některé z harmonických frekvencí tónu. Protože je harmonických frekvencí teoreticky nekonečné množství, parametrem metriky je do jakého celočíselného násobku se ještě odhad počítá.

$$\text{RHA}(\mathbf{f}, \mathbf{f}^*, n) = \frac{\sum_{k=1}^n \sum_{\tau} v_{\tau}^* v_{\tau} \mathcal{T}[\mathcal{M}(f_{\tau}) - \mathcal{M}(kf_{\tau}^*)]}{\sum_{\tau} v_{\tau}^*}$$

¹která byla přítomna i v nejpoužívanější, veřejné implementaci MIR metrik *mir_eval*. V praxi chyba této metriky na datasetu MedleyDB mohla dosahovat až sedmi procentních bodů, na repozitáři hostovaném na serveru Github jsme již spolu s autory chybu odstranili (odkaz na Github issue: https://github.com/craffel/mir_eval/issues/311). Opravný patch bude zahrnut do další verze balíku. Výsledky v této práci jsou počítány s opravenou verzí.

Matice záměn not

Pro podrobnější souhrnný přehled četností chyb se pro klasifikační úlohy používá matice záměn. Sloupce označují správné noty, řádky odhadované. Buňka na pozici (x,y) má pak hodnotu podle četnosti odhadu noty y místo správné noty x .

5. Experimenty

V této kapitole prezentujeme přehled výsledků různých architektur pro extrakci melodie, trénované nad datasetem MedleyDB. Data byla rozdělena na trénovací, validační a testovací množinu tak, aby skladby od jednoho interpreta náležely právě do jedné z množin. Využili jsme existujícího rozdělení používaného v článcích Bittner a kol. (2017) a D Basaran, S Essid (2018), validační i testovací výsledky jsou tedy díky tomu porovnatelné s výsledky uvedenými v článcích.


Pro odhad výšky tónů porovnáváme architektury inspirované pracemi Kim a kol. (2018), van den Oord a kol. (2016a) a Bittner a kol. (2017). V prvním případě jde o architekturu CREPE původně navrženou pro sledování výšky tónů v jednohlasých nahrávkách. van den Oord a kol. (2016a) používají WaveNet složený z dilatovaných konvolucí pro generování lidské řeči. Bittner a kol. (2017) používá hlubokou konvoluční síť pro kompletní přepis nahrávek i pro přepis melodie.

Pro detekci melodie pak srovnáváme jednoduchou metodu práhování a složitější samostatný modul, založený na hlubokých neuronových sítích.

5.1 Architektura CREPE

První sada experimentů se zakládá na architektuře popsané v článku od Kim a kol. (2018) použité pro sledování jednohlasu. Jak blíže popisujeme v kapitole Související práce, cílem monopitch trackingu je určit konturu základní frekvence melodického nástroje v jednohlasé nahrávce. Tato nahrávka se zpravidla skládá ze směsi čistého signálu hlasu a šumu v pozadí. Pokud však rozšíříme pojem šumu v pozadí tak, aby zahrnoval i melodický doprovod, pak dostáváme polyfonní signál, tedy vstupní signál pro metody extrakce melodie.

Jinými slovy je sledování jednohlasu speciálním případem extrakce melodie a tudíž přinejmenším stojí za zkoušku pokusit se tuto architekturu pro extrakci využít. Mimo to jednohlasé stopy často obsahují přeslech ostatních nástrojů, pokud nahrávka vznikala při společném hraní ve studiu, tudíž by model trénovaný na vícehlasé mixech mohl být robustní vůči tomuto druhu rušení.



Obrázek 5.1: Diagram architektury CREPE, multiplikační koeficient 16x.

Architektura CREPE se skládá ze šesti konvolučních a pooling vrstev, pro regularizaci používá batch normalization a dropout po každé konvoluční vrstvě,

jako nelineární aktivace je použita funkce ReLU. Po konvolucích následuje výstupní plně propojená vrstva, jako finální aktivační funkce je použita sigmoida. Vstupem modelu je okno o velikosti 1024 vzorků jednokanálového audio signálu, převzorkovaného na 16 kHz. Před první konvolucí je signál normalizován tak, aby každé jednotlivé vstupní okno mělo střední hodnotu 0 a směrodatnou odchylku 1. Podrobnější popis modelu je naznačen na obrázku.

Výsledný vektor o 640 složkách aproximuje pravděpodobnostní rozdělení výšky základní frekvence uprostřed vstupního okna, přičemž tento vektor pokrývá rozsah od noty C_{-1} po G_9 , mezi dvěma sousedními predikovanými tóny je vzdálenost 20 centů. Výšky tónů v centech označíme $\zeta_1, \zeta_2, \dots, \zeta_{640}$. Rozsah tedy bezpečně pokrývá obvyklé hudební nástroje a na jednu notu připadá 5 složek (tónů) výsledného vektoru.

$$\zeta(f) = 1200 \log_2 \frac{f}{f_{\text{ref}}}$$

Pro trénování modelu potřebujeme také cílové diskretní pravděpodobnostní rozdělení základní frekvence tónu. Jako cílovou pravděpodobnostní funkci použijeme normální rozdělení se střední hodnotou v bodě cílové základní frekvence $\zeta(f_{\text{ref}})$ a se směrodatnou odchylkou 25 centů. Toto rozdělení diskretizujeme tak, aby měl cílový vektor stejné dimenze jako odhadovaný.

$$y_i = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(\zeta_i - \zeta_{\text{ref}})^2}{2\sigma^2}\right)$$

Převod z pravděpodobnostní reprezentace výstupního vektoru na konkrétní hodnotu výšky noty provedeme pomocí výpočtu střední hodnoty výstupní distribuce. Jelikož by při výpočtu střední hodnoty ale hodnotu výsledné výšky tónu ovlivňoval i doprovod, který se na výstupním vektoru objevuje, počítáme střední hodnotu pouze z okolí maxima výstupu. Tím zajistíme, že získáme střední hodnotu gaussiánu náležícímu pouze jednomu tónu.

$$\hat{\zeta} = \sum_{i: |\zeta_i - \zeta_m| < 50} \hat{y}_i \zeta_i \Bigg/ \sum_{i: |\zeta_i - \zeta_m| < 50} \hat{y}_i, m = \text{argmax}_i(\hat{y}_i)$$

Optimalizovaná ztrátová funkce modelu (loss funkce) $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})$ se počítá jako vzájemná korelace mezi vektorem cílových pravděpodobností \mathbf{y} a výstupním vektorem $\hat{\mathbf{y}}$.

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = \sum_{i=1}^{640} (-y_i \log \hat{y}_i - (1 - y_i) \log(1 - \hat{y}_i))$$

Optimalizace probíhá pomocí algoritmu Adam (Kingma a Ba, 2014) s parametrem learning rate 0.0002.

5.1.1 Replikace výsledků CREPE

Abychom ověřili správnost implementace architektury CREPE pro sledování jednohlasu, spustíme model na syntetických, jednohlasých datech MDB-stem-synth, která byla zveřejněná spolu s článkem od Salamon a kol. (2017).

Na rozdíl od článku Kim a kol. (2018), ve kterém autoři používají pro celkové vyhodnocení architektury pětinasobnou křížovou validaci, jsme použili pouze

	1.	2.	3.	4.	5.	6.	Celk. parametrů
CREPE 4x	128	16	16	16	32	64	558 240
CREPE 8x	256	32	32	32	64	128	177 1200
CREPE 16x	512	64	64	64	128	256	6 163 200

Tabulka 5.1: Počty filtrů v konvolučních vrstvách v architektuře CREPE v závislosti na multiplikačním koeficientu.

jednu trénovací a testovací množinu. Zásadní rozdíly mezi implementacemi modelu jsme na základě článku a veřejně dostupného kódu neobjevili.

Po jedné epoše trénování model dosáhl na testovací množině 98.6% přesnosti odhadu výšky. Kim a kol. (2018) uvádí přesnost modelu 97%. V jejich případě jde o průměrný výsledek pěti nezávislých běhů trénování a testování na různě rozdělených datových množinách. Rozdíl mezi dosaženými přesnostmi přičítáme odlišné evaluační strategii.

Metrika	Práh	Průměrná hodnota	Hodnota Kim a kol. (2018)
RCA	50 centů	0.988	0.970
RPA	50 centů	0.986	0.967
RPA	25 centů	0.975	0.953
RPA	10 centů	0.937	0.909

Tabulka 5.2: Výsledky pokusu o replikaci. Přesnosti nejsou přímo srovnatelné kvůli různým evaluačním strategiím.

Při replikaci experimentu jsme narazili na důležitost správného promíchání dat. Framework Tensorflow použitý pro trénování promíchává data vždy pomocí bufferu pevné velikosti pro dvojice vstupů a cílových výstupů. V praxi je však potřeba buď nastavit buffer na velikost větší než je celková velikost datasetu, a nebo implementovat vlastní míchání přes všechna dostupná data. Při nedostatečně promíchaných datech totiž trénovací dávka (batch) není reprezentativní pro celý dataset, ale pouze pro jeho podmnožinu, což se negativně projevuje kolísající validační přesností modelu.


5.1.2 CREPE pro extrakci melodie

Jako první experiment extrakce melodie z polyfonních dat spustíme nezměněnou architekturu CREPE, v následujících experimentech se tuto baseline pokusíme překonat. Abychom urychlili trénování následujících experimentů, přesnost určíme pro sítě s různou kapacitou. Pokud se výsledky při různých kapacitách nebudou příliš lišit, můžeme experimenty provádět s architekturou s nižší kapacitou a tím snížit trénovací čas. Kapacity upravíme pomocí multiplikačního koeficientu počtu filtrů u všech konvolučních vrstev, počty filtrů jsou uvedeny v tabulce 5.2.

Z validačních výsledků po 200 000 iteracích (přibližně 6 epoch) vidíme, že se výsledek modelů CREPE 8x a CREPE 16x liší řádově o desetiny procentních bodů. Přitom model s větší kapacitou se trénuje o 35% delší dobu. Proto pro další srovnávání zvolíme architektury s multiplikačním koeficientem 8, modely s dobrými výsledky případně přetrénujeme s vyšší kapacitou.

Mult. koef. capacity	RPA	RCA
4	0.634	0.753
8	0.661	0.766
16	0.666	0.771
32	0.656	0.753

Tabulka 5.3: Výsledky experimentu s různými kapacitami modelu.



Obrázek 5.2: Výsledky experimentu s různými kapacitami modelu.

5.1.3 Vliv rozlišení diskretizace výšky noty


Otestujeme nastavení granularity výstupního vektoru. V článku Kim a kol. (2018) se totiž důvod volby pěti frekvencí na notu nediskutuje. Intuitivně by však mělo vyšší rozlišení spíše pomáhat, důvodem je, že nástroje a zejména lidský hlas se často při hraní odchylují od přesných, definovaných frekvencí hraných not a vyšší rozlišení tyto odchylky může lépe zachytit. Ve výsledku by pak síť s jemnějším výstupem měla dělat méně chyb, kde se skutečná a výstupní hodnota liší o jeden půltón.

Jemnost diskretizace	RPA	RCA
1	0.612	0.711
3	0.653	0.760
5	0.666	0.771
7	0.654	0.763
9	0.658	0.760


Tabulka 5.4: Architektura CREPE s různou jemností diskretizace.

Jak můžeme pozorovat na výsledných hodnotách, jemná granularita výstupu jednoznačně zlepšuje přesnost sítě. Abychom ověřili domněnku, že vyšší rozlišení pomáhá zmenšit počet chyb o půltón, vytvoříme histogram vzdáleností cílového a odhadovaného tónu. V tomto histogramu by pak měl být zřetelný pokles v příslušných třídách. Podle histogramu se počet chyb o půltón mezi zkoumanými modely liší téměř o polovinu, zlepšení tohoto druhu chyb je tedy podstatné.

odsud dolů přepsat



Obrázek 5.3: Architektura CREPE s různou jemností diskretizace.



Obrázek 5.4: Histogramy vzdálenosti chybného odhadu, výstup prvního modelu má rozlišení 50 centů, výstup druhého 10 centů.

5.1.4 Vliv rozptylu cílové pravděpodobnostní distribuce výšky noty

Podle Bittner a kol. (2017) pomáhá cílová distribuce s vyšším rozptylem snížit penalizaci sítě za téměř korektní odhady výšek tónů. Mimo to u dostupných dat často nejsou anotace naprosto perfektní, jisté rozostření hranice anotace tudíž pomáhá i v případě nepřesné cílové anotace, síť pak není tolik penalizována za svou případnou správnou odpověď.

V článku se však nediskutuje, proč bylo zvoleno nastavení směrodatné odchylky na 20 centů. Kim a kol. (2018) používá odchylku 25 centů a není na první pohled zřejmé, jaká je optimální hodnota. Příliš vysoký rozptyl způsobí, že síť bude tolerovat více chyb o půltón, příliš nízký rozptyl naopak penalizuje i téměř správné odhady. Intuitivně se nejlepší nastavení pravděpodobně bude pohybovat kolem používaných 25 centů, jelikož to je hranice chybné klasifikace, na druhou stranu optimální hodnota jistě bude závislá na nastavení rozlišení výstupního vektoru, jelikož nižší rozlišení bude jistě vyžadovat vyšší hodnotu rozptylu (v extrémním případě rozptylu blízkého se k nule a cílové frekvence mimo kvantizační hladiny by vzniklý cílový vektor nemusel obsahovat žádné ostré maximum).


Poznamenám také technický detail, který je důležitý při samotné implementaci. Přestože jsem cílový výstup sítě zadefinoval jako diskrétní pravděpodobnostní rozdělení, při trénování je tento vektor hodnot pronásoben koeficientem

tak, aby $\max(\mathbf{y}) = 1.0$ a tedy součet prvků vektoru není roven jedné (a o pravděpodobnostní rozdělení se doopravdy nejedná). Důvodem je použití aktivační funkce *sigmoid* u výstupní vrstvy, která nezaručuje výstup korektního rozdělení. Díky tomu se na výstupu může objevit různé množství stejně pravděpodobných kandidátů na melodii.

Testovaná síť má vstupní okno široké 4096 vzorků, používá multiplikátor kapacity 16x a vstup zpracovává 6 různě širokými konvolučními vrstvami (viz experiment *Vliv násobného rozlišení první konvoluční vrstvy*).

Rozptyl	RPA	RCA
0.000	0.657	0.759
0.088	0.672	0.775
0.124	0.677	0.773
0.177	0.689	0.784
0.221	0.677	0.771
0.265	0.677	0.770
0.354	0.669	0.773
0.707	0.654	0.757

Tabulka 5.5: Architektura CREPE, vliv rozptylu cílové distribuce.



Obrázek 5.5: Architektura CREPE, vliv rozptylu cílové distribuce.


Z experimentů vyplývá, že optimální směrodatná odchylka se pohybuje kolem hodnoty 0.177, tedy níže než v porovnávaných pracích.

5.1.5 Vliv šířky vstupního okna

Architektura CREPE byla navržena pro monopitch tracking, dá se předpokládat, že jelikož je v monofonních nahrávkách oproti polyfonním daleko méně (melodického) šumu, není pro určení výšky tónu potřeba větší kontext než použitých 1024 vzorků (při vzorkovací frekvenci 16kHz toto odpovídá 64 milisekundám audia). To ale nemusí platit pro složitější signály, kde by síť mohla z delšího kontextu těžit. Otestujeme tedy vliv většího vstupního okna na výslednou přesnost.

Šířka vstupního okna	RPA	RCA
512 (32 ms)	0.634	0.748
1024 (64 ms)	0.645	0.763
2048 (128 ms)	0.648	0.760
4096 (256 ms)	0.650	0.762
8192 (512 ms)	0.675	0.775

Tabulka 5.6: Architektura CREPE, vliv šířky vstupního okna.



Obrázek 5.6: Architektura CREPE, vliv rozptylu cílové distribuce.

5.1.6 Vliv násobného rozlišení první konvoluční vrstvy

Podle Kim a kol. (2018) se přesnost CREPE snižuje s výškou tónu. Autoři si tuto skutečnost vysvětlují neschopností modelu generalizovat na barvy a výšky tónů neobsažených v trénovací množině, generalizaci by ale mohla pomoci také úprava modelu. Protože k rozpoznání vyšších frekvencí stačí méně vzorků než pro rozpoznání nižších, mohli bychom se pokusit upravit první konvoluční vrstvu sítě, která tento úkol zastává, a rozdělit ji na množiny různě širokých konvolucí, jejichž kanály následně sloučíme zpět do jednotné vrstvy. To by mělo mít za následek, že rozpoznávání vysokých tónů budou zastávat užší konvoluce a jejich kernel bude jednodušší než široké kernely s vysokou mírou redundance.

První vrstvu s kernelem s 256 filtry (tj. počet filtrů první vrstvy s multiplikátorem 8x, viz první experiment) jsem rozdělil na vícero různě širokých kernelů s menším počtem filtrů, tak aby kapacita sítě zůstala přibližně stejná a síť byly porovnatelné.


Šířka vrstev	512	256	128	64	32	16	8	4	Počet parametrů
Počet vrstev									
1	256								2098880
2	128	128							2066112
3	85	85	85						2041918
4	64	64	64	64					2029248
5	51	51	51	51	51				2016350
6	42	42	42	42	42	42			2001944
7	36	36	36	36	36	36	36		1996184
8	32	32	32	32	32	32	32	32	2000448

Tabulka 5.7: Počet filtrů prvních vrstev multirezoluční vstupní konvoluční vrstvy.

Experiment jsem provedl na síti se vstupním oknem 2048 vzorků, multiplikátorem kapacity 8,

Počet konvolučních vrstev	RPA	RCA
1	0.669	0.779
2	0.669	0.773
3	0.672	0.773
4	0.674	0.778
5	0.686	0.781
6	0.678	0.780
7	0.677	0.779
8	0.680	0.778

Tabulka 5.8: Architektura CREPE, vliv multirezoluční vstupní konvoluční vrstvy.




Obrázek 5.7: Architektura CREPE, vliv multirezoluční vstupní konvoluční vrstvy.

Zlepšení výsledků se pohybuje v řádu desetin procentních bodů, tedy není příliš vysoké. Zlepšení je nejvíce patrné v případě pěti různě širokých konvolučních vrstev, kde dosahuje 1.3 procentního bodu. Analýzou výsledků přesnosti podle výšky noty se mi nepodařilo prokázat domněnku, že by konvoluce s více rozlišenými pomáhala u odhadu not vyšších frekvencí. Její přínos je drobný a projevuje se na většině frekvenčních pásem.

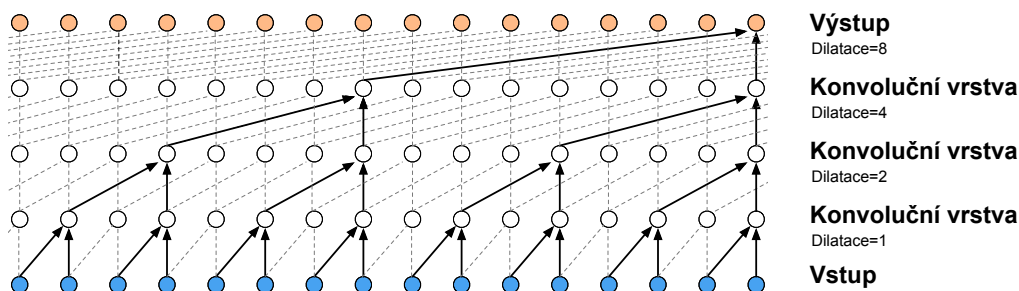
5.2 Architektura WaveNet

Generativní model WaveNet popsáný týmem van den Oord a kol. (2016a) je architektura navržená pro generování zvukového signálu. Autoři však v článku zmiňují, že se architekturu pokusili využít i pro převod mluvené řeči na text (dataset TIMIT), a podařilo se jim dosáhnout výsledků srovnatelných se state-of-the-art. Architektura spočívá ve vrstvení dilatovaných konvolucí s rozšiřujícím se rozsahem. Díky exponenciálně rostoucím dilatacím se také exponenciálně zvětšuje receptivní pole jednotlivých konvolučních vrstev. Díky této vlastnosti pak například stačí pro pokrytí 1024 vzorků vstupu pouze 9 vrstev s šířkou kernelu 2 a dilatacemi 1,2,4,8 ... 512. Pokud bychom stejného receptivního pole chtěli

dosáhnout pomocí obvyklých konvolucí počet potřebných vrstev by byl lineární vzhledem k šířce pole. Vrstvení konvolucí je porovnáno na obrázcích 5.8 a 5.9. Sít tedy velmi snadno pokryje široký kontext, což je vlastnost, která je pro zpracování zvukového signálu užitečná.



Obrázek 5.8: Vrstvení obyčejných konvolucí s lineárně rozšiřovaným dosahem, obrázek převzat z van den Oord a kol. (2016a).




Obrázek 5.9: Vrstvení dilatovaných konvolucí s exponenciálně rozšiřovaným dosahem, obrázek převzat z van den Oord a kol. (2016a).

Sít se pro Music Information Retrieval úlohy od svého zveřejnění příliš neuchytila. Její použití se v oblasti hudby se omezuje na generativní úlohy (Hawthorne a kol. (2018), Yang a kol. (2017), Engel a kol. (2017) a další), případně pro source-separation (Stoller a kol., 2018). Jediný publikovaný pokus s použitím architektury WaveNet pro příbuznou úlohu kompletního automatického přepisu podnikli Martak a kol. (2018) s použitím datasetu MusicNet. Jejich model však netestovali na standardních evaluačních datasetech ze soutěže MIREX, tudíž není zřejmé, jakých výsledků v porovnání s existujícími metodami autoři dosáhli.

5.2.1 Baseline na základě Martak a kol. (2018)


Pro extrakci melodie využijeme jako výchozí model upravenou architekturu od Martak a kol. (2018), jejíž struktura je naznačena na obrázku 5.10. Vstupem je okno velikosti 4894 vzorků audia převzorkovaného na 16 kHz, toto okno nejprve zpracujeme standardní konvoluční vrstvou s šířkou kernelu 2 a 128 výstupními kanály, takto zpracovaný signál dále prochází dvěma bloky po desíti vrstvách, které obsahují dilatované konvoluce. Vrstvy obsahují dvě dilatované konvoluce, jednu s aktivací hyperbolickým tangens a jednu s aktivací funkcí sigmoid. Výstupy těchto konvolucí jsou po složkách vynásobeny, díky čemuž konvoluce s aktivací sigmoid funguje jako nastavitelná propust signálu (Gated activation unit,



Obrázek 5.10: Architektura WaveNet upravená pro kompletní přepis skladeb, upraveno na základě Martak a kol. (2018).

van den Oord a kol. (2016b)), poté je výstup opět zpracován dvěma konvolucemi, tentokrát se šířkou kernelu 1×1 . Výstup první sečteme s původním vstupem celé vrstvy (jedná se o residuální propojení poprvé popsané v práci He a kol. (2015)) a zpracujeme ho nadcházející vrstvou. Výstup druhé konvoluce (autoři tuto cestu nazývají *skip propojení*) zařadíme mezi výstupy skip propojení všech ostatních vrstev.


Pro výpočet odhadů výšky tónu sečteme všechna skip propojení, tento součet zpracujeme dvěma konvolucemi, druhá z nich má na výstupu 128 kanálů zpracovaných sigmoidou, což odpovídá rozsahu odhadovaných not. Jelikož všechny popsané transformace zachovávají šířku vstupu, dostáváme po této konvoluci odhady výšek not pro každý vstupní vzorek zvuku, taková anotace je zbytečně podrobná, tudíž výsledné anotace podvzorkujeme pomocí pooling vrstvy počítající průměr hodnot.



Obrázek 5.11: Vývoj ztrátové funkce při učení architektury Martak a kol. (2018) pro extrakci melodie. Zatímco hodnoty pro trénovací množinu mají klesající tendenci, hodnoty na validační množině rostou, síť se velmi rychle přeučuje.

Po 20 000 iteracích s velikostí dávky 20 a parametrem learning rate 0.001 síť dosahuje na validačních datech přesnost odhadu tónu 0.583 (RPA) a přesnost odhadu tónu nezávisle na oktávě 0.692 (RCA). V porovnání s výsledky architektury CREPE jsou tyto výsledky výrazně nižší, krom toho učení sítě trvá velmi dlouho (14 minut na 1000 iterací), zejména kvůli obrovské kapacitě a topologické komplexitě modelu (2 009 728 trénovatelných parametrů). Veliká kapacita modelu také způsobuje přeučení sítě (viz 5.11), pokusíme se tedy zrychlit trénování a zabránit přeučení výrazným snížením počtu filtrů dilatačních a skip propojení ze 128 na 16, a použitím pouze jednoho dilatačního bloku. Také snížíme velikost trénovací dávky na 8 pro další zrychlení učení. Nová síť obsahuje 10 vrstev s dilatacemi (1, 2, 4, 8, ..., 512), a tedy 34 736 parametrů a dosahuje RPA 0.598 a RCA 0.696 po 100 000 iteracích při rychlosti trénování 30 sekund na 1000 iterací. Síť tedy dosahuje stejných výsledků ve výrazně kratším čase.

Z předchozích experimentů na architektuře CREPE víme, že jemnější výstupní reprezentace pomáhá snížit počet chyb o půltón, upravíme tedy síť tak, aby na jeden půltón připadalo 5 výstupních složek vektoru, zmenšíme výstupní frekvenční rozsah a hodnoty cílového vektoru změním z ostré predikce konkrétního tónu na „rozmlžený“ gaussian se směrodatnou odchylkou 18 centů (pro podrobnější popis viz 5.1). Síť po této úpravě dosahuje RPA 0.629 a RCA 0.731 po 100 000 iteracích.



Obrázek 5.12: Úprava posledních vrstev WaveNet architektury.


Předběžným hledáním výchozí architektury pro nadcházející sadu experimentů jsme došli k následujícím úpravám. Dilatované konvoluce ve všech vrstvách mají šířku 3 místo 2, jejich vstup tedy závisí na všech okolních vzorcích, nikoli jen na předchozích, jak je naznačeno na obrázku 5.9. Dále jsme odstranili konvoluční vrstvu, která zpracovává vstup, ten je tedy přímo zpracován dilatačním blokem. Ze skip propojení se zpracovává pouze poslední, nedochází ke sčítání všech, což je úprava, kterou pro přepis řeči používají původní autoři článku WaveNet van den Oord a kol. (2016a). Tento výstup je následně zpracován pooling vrstvou a dvěma konvolucemi se skoky (stride), viz obrázek 5.12. Tato síť dosahuje RPA 0.655 a RCA 0.759 po 100 000 iteracích a je základem pro následující experimenty.

5.2.2 Vliv počtu filtrů dilatačních vrstev a skip propojení

Jedním ze zásadních faktorů ovlivňujících kapacitu sítě je počet filtrů dilatačních vrstev a skip propojení. Tyto kanály nesou informaci o vzorku a jeho okolí, v závislosti na vrstvě dilatace. Výstup poslední vrstvy má tedy délku počtu vstupních vzorků 2848 a 16 kanálů. Každý výstupní vzorek nese informaci o svém okolí délky 2047. Podobně jako v případě architektury CREPE nalezneme vhodnou kapacitu sítě tak, aby nedocházelo k přeučení (overfitting) ani k nedoučení (underfitting) na trénovací množině.

Počet kanálů	RPA	RCA
4	0.609	0.714
8	0.628	0.739
16	0.655	0.759
24	0.665	0.764
32	0.671	0.771
40	0.667	0.766
48	0.667	0.764

Tabulka 5.9: Architektura WaveNet, vliv počtu filtrů dilatačních vrstev a skip propojení.



Obrázek 5.13: Architektura WaveNet, vliv počtu filtrů dilatačních vrstev a skip propojení.

Na základě výsledků volíme pro další experimenty nastavení 16 filtrů pro dilatované konvoluce a skip propojení. Při nastavení 24 a více filtrů dosažená přesnost sítě stagnuje, 16 filtrů je kompromisem z hlediska rychlosti trénování.

5.2.3 Systematické prohledávání počtu dilatačních vrstev a bloků

Velikost zpracovávaného kontextu lze v architektuře WaveNet ovlivnit třemi různými hyperparametry. Jde o počet vrstev v bloku n_{layers} , počet dilatačních bloků poskládaných nad sebou n_{stacks} a šířka kernelu dilatací n_{width} . Přesně lze dosah vypočítat jako


$$\text{receptive_field} = (n_{\text{width}} - 1) \cdot \left(\sum_d^{n_{\text{layers}}} 2^{(d-1)} \right) \cdot n_{\text{stacks}} + 1$$

Dosud jsme testovali sítě s jedním blokem o deseti vrstvách s dilatacemi $(1, 2, 4, 8, 16, \dots, 512)$ s šířkou konvolucí 3, její dosah je tedy 2047 vzorků. Systematickým prohledáváním prozkoumáme vliv delšího kontextu měněného pomocí n_{layers} a n_{stacks} . Při vyhodnocování experimentu je nutné vzít v úvahu, že přidání nové vrstvy, případně celého nového bloku, zároveň zvyšuje kapacitu modelu, což také ovlivňuje výslednou přesnost modelu. Šířky kontextu a kapacity jsou uvedené v tabulce 5.10.

V architektuře modelu jsme pro tento experiment provedli změnu ve zpracování skip propojení. V této sadě se nebere poslední skip propojení, nýbrž všechna se spojí v ose kanálů a slouží jako vstup pro následující pooling vrstvu a konvoluci. Z toho důvodu má model mnohem více parametrů, na druhou stranu je zajištěno, že poslední vrstvy mohou využít informace ze všech skip spojení k odhadu výšek. Na základě srovnání tréninkové a validační ztrátové funkce však modely nevykazují známky přeučení.

Max. dilatace	64	128	256	512	1024
Počet bloků					
1 (dosah)	255	511	1023	2047	4095
1 (kapacita)	4 483 644	4 531 836	4 580 028	4 628 220	4 676 412
2 (dosah)	509	1021	2045	4093	8189
2 (kapacita)	4 820 988	4 917 372	5 013 756	5 110 140	5 206 524
3 (dosah)	763	1531	3067	6139	12 283
3 (kapacita)	5 158 332	5 302 908	5 447 484	5 592 060	5 736 636
4 (dosah)	1017	2041	4089	8185	—
4 (kapacita)	5 495 676	5 688 444	5 881 212	6 073 980	—

Tabulka 5.10: Architektura WaveNet, dosah a kapacita v závislosti na dilatačních počtu vrstev a bloků.



Obrázek 5.14: Architektura WaveNet, systematické prohledávání počtu dilatačních vrstev a bloků, vlevo hodnoty RPA, vpravo RCA.

Z tabulky lze dojít k pozorování, že přidávání počtu vrstev zvyšuje výslednou přesnost víceméně vždy, to neplatí o počtu bloků, u kterých se zdá, že nejvhodnější počet je 2. Pokud se zaměříme na srovnání výsledků s podobným dosahem, zdá se že výsledky jsou poměrně podobné, zejména pro širší dosahy, pro kratší se zdá lepší využít spíše více vrstev než více bloků.


5.2.4 Vliv velikosti šířky kernelu dilatací

Jiným způsobem, jak zvýšit velikost zpracovávaného kontextu, je volba velikosti šířky kernelu dilatací n_{width} . Provedeme čtyři experimenty s různou šířkou. Šířka 2 je zvolena v původním článku z toho důvodu, že konvoluce se tím stávají „kauzální“ — jejich výstup závisí pouze na vzorcích před nimi (viz obrázky

5.8, 5.9). To je výhodné pro generativní úlohy, u kterých chceme, aby hodnota nového generovaného vzorku v audio signálu nezávisela na budoucích, zatím neexistujících vzorcích. U klasifikačních úloh takto omezení nejsme, tudíž můžeme s nastavením experimentovat.

Šířka kernelu dilatací	RPA	RCA
2	0.649	0.754
3	0.648	0.755
4	0.656	0.759
5	0.645	0.756

Tabulka 5.11: Architektura WaveNet, vliv velikosti šířky kernelu dilatací.



Obrázek 5.15: Architektura WaveNet, vliv velikosti šířky kernelu dilatací.

Z tabulky 5.11 a grafu 5.15 vyplývá, že tato síť při změnách šířky kernelu dilatace svou výslednou přesnost na validačních datech nemění.


5.2.5 Vliv výstupní transformace skip propojení

Volba transformace skip propojení se v článku týmu van den Oord a kol. (2016a) nediskutuje, Martak a kol. (2018) také přejímají součet všech skip výstupů. Vyzkoušíme proto dvě další možnosti práce se skip propojeními - výběr posledního skip propojení a dále konkatenace všech skip propojení do mnohakanálového výstupu. V případě výběru posledního či součtu jde o transformace, které lze popsat konvolucí nad konkatenovanými skip propojeními. Dalo by se tedy říct, že výběr a součet jsou v tomto případě speciálními případy konkatenace výstupů. Výběr poslední vrstvy také znamená, že nejsou potřeba předchozí skip propojení, což urychluje trénování.

Transf. skip vrstev	RPA	RCA
Konkatenace	0.654	0.754
Poslední	0.651	0.754
Součet	0.646	0.753

Tabulka 5.12: Architektura WaveNet, vliv výstupní transformace skip propojení.

Všechny tři transformace vedou ke stejné přesnosti. Síť tedy netěží z větších možností práce s dřívejšími vrstvami a nejdůležitější informace se objevují až na vrchu bloků dilatovaných konvolucí.



Obrázek 5.16: Architektura WaveNet, vliv výstupní transformace skip propojení.


5.2.6 Vliv velikosti první konvoluce

van den Oord a kol. (2016a) používá pro předzpracování zvukového signálu obvyklou konvoluci, nespecifikuje však její šířku. Veřejná implementace architektury WaveNet pracuje s šířkou 32 ¹. Martak a kol. (2018) používají šířku 2, čímž fakticky jen duplikují první dilatační vrstvu. První vrstva může sloužit jako banka filtrů, podobně jako první vrstva v architektuře CREPE, pro tento účel však musí být široká minimálně 512 vzorků, aby mohla zachytit periodu i té nejnižší frekvence ve výstupním rozsahu.

vizualizace první vrstvy? Co tam vlastně může být, když pomáhá šestnácti smplová konvoluce?

Velikost první vrstvy	RPA	RCA
0	0.648	0.755
8	0.663	0.762
16	0.661	0.765
32	0.654	0.754
64	0.643	0.756
256	0.609	0.735
1024	0.601	0.734

Tabulka 5.13: Architektura WaveNet, vliv velikosti první konvoluce.



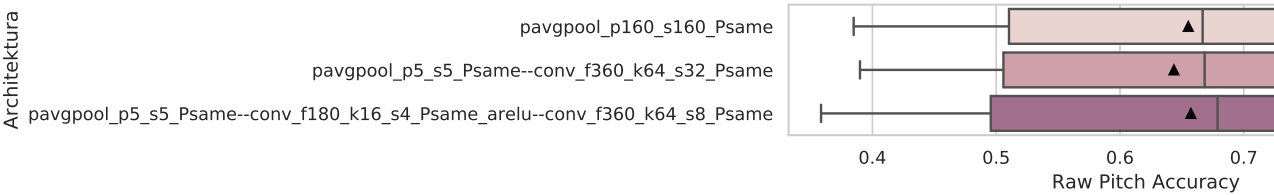
Obrázek 5.17: Architektura WaveNet, vliv velikosti první konvoluce.

TODO: Dopsat vyhodnocení

5.2.7 Vliv návrhu posledních vrstev

¹https://github.com/ibab/tensorflow-wavenet/blob/master/wavenet_params.json

Tabulka 5.14: Architektura WaveNet, vliv návrhu posledních vrstev.



Obrázek 5.18: Architektura WaveNet, vliv návrhu posledních vrstev.

6. Výsledky

Závěr

Seznam použité literatury

BITTNER, R., SALAMON, J., TIERNEY, M., MAUCH, M., CANNAM, C. a BELLO, J. (2014). MedleyDB: A multitrack dataset for annotation - intensive mir research. *International Society for Music Information Retrieval Conference*.

BITTNER, R. M. (2018). Data-Driven Fundamental Frequency Estimation.

BITTNER, R. M., MCFEE, B., SALAMON, J., LI, P. a BELLO, J. P. (2017). Deep Saliency Representations for F0 Estimation in Polyphonic Music. *Ismir*, pages 23–27. URL https://bmcfee.github.io/papers/ismir2017_{_}saliency.pdf.

BOSCH, J. J. a GÓMEZ, E. (2016). Melody Extraction Based on a Source-Filter Model Using Pitch Contour Selection. *13th Conference on Sound and Music Computing*, pages 67–74.

BOSCH, J. J., MARXER, R. a GÓMEZ, E. (2016). Evaluation and combination of pitch estimation methods for melody extraction in symphonic classical music. *Journal of New Music Research*, **45** (2), 101–117. ISSN 17445027. doi: 10.1080/09298215.2016.1182191. URL https://repositori.upf.edu/bitstream/handle/10230/26985/Bosch_{_}NewMusic_{_}Eval.pdf?sequence=1{&}isAllowed=y.

BROWN, J. C. (1990). Calculation of a constant Q spectral transform. *The Journal of the Acoustical Society of America*, **89**(1), 425–434. ISSN 0001-4966. doi: 10.1121/1.400476. URL <http://academics.wellesley.edu/Physics/brown/pubs/cq1stPaper.pdf>.

CANCELA, P. (2008). Tracking melody in polyphonic audio. *4th Music Information Retrieval Evaluation eXchange*. URL <https://pdfs.semanticscholar.org/226e/a7b870fd229149fae2e6c8b15d8a3d4f9bb8.pdf>.

D BASARAN, S ESSID, G. P. (2018). Main melody extraction with source-filter nmf and crnn. *Ismir*, pages 82–89. URL http://ismir2018.ircam.fr/doc/pdfs/273_{_}Paper.pdf.

DOWNIE, J. S., EHMANN, A. F., BAY, M. a JONES, M. C. (2010). eXchange : Some Observations and Insights. *Advances in Music Information Retrieval*, pages 93–115. URL <https://pdfs.semanticscholar.org/3836/15607f345a8cfbc5e884eaa5ca04f3c4b139.pdf>.

DRESSLER, K. (2009). Audio melody extraction for mirex 2009. *Evaluation eXchange (MIREX)*, pages 1–3. URL http://www.idmt.fraunhofer.de/content/dam/idmt/de/Dokumente/Produktflyer/QbH/white_{_}paper_{_}fraunhofer_{_}idmt_{_}audio_{_}melody_{_}extraction_{_}mirex_{_}2009.pdf.

- DRESSLER, K. (2011). Pitch estimation by the pair-wise evaluation of spectral peaks. *42nd AES Conference*, pages 1–10. URL <http://www.aes.org/e-lib/browse.cfm?elib=15960>.
- DRESSLER, K. (2016). Automatic Transcription of the Melody from Polyphonic Music. URL https://www.db-thueringen.de/servlets/MCRFileNodeServlet/dbt_{_}derivate_{_}00038847/ilm1-2017000136.pdf.
- DURRIEU, J.-L. a DAVID, B. (2010). Source / Filter Model for Unsupervised Main Melody. **18**(3), 1–12. URL https://www.irit.fr/{~}Cedric.Fevotte/publications/journals/ieee_{_}asl_{_}voice_{_}extrac.pdf.
- ENGEL, J., RESNICK, C., ROBERTS, A., DIELEMAN, S., ECK, D., SIMONYAN, K. a NOROUZI, M. (2017). Neural Audio Synthesis of Musical Notes with WaveNet Autoencoders. URL <http://arxiv.org/abs/1704.01279>.
- GABOR, B. D. a MEMBER, A. (1945). THEORY OF COMMUNICATION * Part 1 . THE ANALYSIS OF INFORMATION. *Journal of the Institution of Electrical Engineers-Part III: Radio and Communication Engineering*, **93** (1946), 429–441.
- GOTO, M. a HAYAMIZU, S. (1999). A real-time music scene description system: Detecting melody and bass lines in audio signals. *IJCAI-99 Workshop on Computational Auditory Scene Analysis*, (August), 31–40. URL <http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.33.1085{&}rep=rep1{&}type=pdf>.
- HAWTHORNE, C., STASYUK, A., ROBERTS, A., SIMON, I., HUANG, C.-Z. A., DIELEMAN, S., ELSEN, E., ENGEL, J. a ECK, D. (2018). Enabling Factorized Piano Music Modeling and Generation with the MAESTRO Dataset. pages 1–12. URL <http://arxiv.org/abs/1810.12247>.
- HE, K., ZHANG, X., REN, S. a SUN, J. (2015). Deep Residual Learning for Image Recognition. URL <http://arxiv.org/abs/1512.03385>.
- HERMES, D. J. (1988). Measurement of pitch by subharmonic summation. *The Journal of the Acoustical Society of America*, **83**(1), 257–264. ISSN 0001-4966. doi: 10.1121/1.396427. URL <http://asa.scitation.org/doi/10.1121/1.396427>.
- IKEMIYA, Y., ITOYAMA, K. a YOSHII, K. (2016). Singing Voice Separation and Vocal F0 Estimation Based on Mutual Combination of Robust Principal Component Analysis and Subharmonic Summation. *IEEE/ACM Transactions on Audio Speech and Language Processing*, **24**(11), 2084–2095. ISSN 23299290. doi: 10.1109/TASLP.2016.2577879.
- KIM, J. W., SALAMON, J., LI, P. a BELLO, J. P. (2018). Crepe: A Convolutional Representation for Pitch Estimation. *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings*, **2018-April**, 161–165. ISSN 15206149. doi: 10.1109/ICASSP.2018.8461329. URL <https://arxiv.org/pdf/1802.06182.pdf>.

- KINGMA, D. P. a BA, J. (2014). Adam: A Method for Stochastic Optimization. pages 1–15. URL <http://arxiv.org/abs/1412.6980>.
- MARTAK, L. S., SAJGALIK, M. a BENESOVA, W. (2018). Polyphonic Note Transcription of Time-Domain Audio Signal with Deep WaveNet Architecture. *International Conference on Systems, Signals, and Image Processing*, **2018-June**, 2–6. ISSN 21578702. doi: 10.1109/IWSSIP.2018.8439708. URL https://vgg.fiit.stuba.sk/wp-uploads/2018/09/iwssip2018_{_}wavenet.pdf.
- MAUCH, M. a DIXON, S. (2014). PYIN: A fundamental frequency estimator using probabilistic threshold distributions. *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings*, **1**(1), 659–663. ISSN 15206149. doi: 10.1109/ICASSP.2014.6853678. URL <https://www.eecs.qmul.ac.uk/{~}simond/pub/2014/MauchDixon-PYIN-ICASSP2014.pdf>.
- PAIVA, R. P., MENDES, T. a CARDOSO, A. (2004). An Auditory Model Based Approach for Melody Detection in Polyphonic Musical Recordings. (May 2014), 21–40. doi: 10.1007/978-3-540-31807-1_2.
- PFLEIDERER, M., FRIELER, K., ABESSER, J., ZADDACH, W.-G. a BURKHART, B. *Inside the Jazzomat*. ISBN 9783959831246. URL http://schott-campus.com/wp-content/uploads/2017/11/inside_{_}the_{_}jazzomat_{_}final_{_}rev_{_}oa4.pdf.
- POLINER, G. E., MEMBER, S., ELLIS, D. P. W., MEMBER, S., EHMANN, A. F., GÓMEZ, E., STREICH, S. a ONG, B. (2007). Melody Transcription From Music Audio : Approaches and Evaluation. *Ieee Transactions on Audio, Speech, and Language Processing*, **15**(4), 1247–1256. doi: 10.1109/TASL.2006.889797. URL <https://academiccommons.columbia.edu/doi/10.7916/D8NC69RK/download>.
- RAFFEL, C., MCFEE, B., HUMPHREY, E. J., SALAMON, J., NIETO, O., LIANG, D. a ELLIS, D. P. W. (2014). mir_eval: A Transparent Implementation of Common MIR Metrics. *Proceedings of the 15th International Society for Music Information Retrieval Conference (ISMIR 2014)*, pages 367–372. URL https://bmcfree.github.io/papers/ismir2014_{_}mireval.pdf.
- RAO, V. a RAO, P. (2010). Vocal melody extraction in the presence of pitched accompaniment in polyphonic music. *IEEE Transactions on Audio, Speech and Language Processing*, **18**(8), 2145–2154. ISSN 15587916. doi: 10.1109/TASL.2010.2042124. URL <https://www.ee.iitb.ac.in/course/{~}daplab/publications/PrePrintForWebsite.pdf>.
- RYYNÄNEN, M. P. a KLAPURI, A. P. (2008). Automatic Transcription of Melody, Bass Line, and Chords in Polyphonic Music. *Computer Music Journal*, **32**(3), 72–86. ISSN 0148-9267. doi: 10.1162/comj.2008.32.3.72.
- SALAMON, J. a GOMEZ, E. (2012). Melody extraction from polyphonic music signals using pitch contour characteristics. *IEEE Transactions on Audio, Speech and Language Processing*, **20**(6), 1759–1770. ISSN 15587916. doi: 10.1109/TASL.2012.2188515.

- SALAMON, J., ROCHA, B. a GOMEZ, E. (2012). Musical genre classification using melody features extracted from polyphonic music signals. *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings*, pages 81–84. ISSN 15206149. doi: 10.1109/ICASSP.2012.6287822. URL <http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.296.5021{&}rep=rep1{&}type=pdf>.
- SALAMON, J., GÓMEZ, E., ELLIS, D. P. a RICHARD, G. (2014). Melody extraction from polyphonic music signals: Approaches, applications, and challenges. *IEEE Signal Processing Magazine*, **31** (2), 118–134. ISSN 10535888. doi: 10.1109/MSP.2013.2271648. URL <http://www.justinsalamon.com/uploads/4/3/9/4/4394963/salamon{ }gomez{ }ellis{ }richard{ }melodyextractionreview{ }ieeespm{ }2013.pdf>.
- SALAMON, J., BITTNER, R. M., BONADA, J., BOSCH, J. J., GOMEZ, E. a JUAN PABLO BELLO (2017). An Analysis/Synthesis Framework for Automatic F0 Annotation of Multitrack Datasets. *Proceedings of the International Society for Music Information Retrieval {(ISMIR)} Conference*, pages 71–78.
- STOLLER, D., EWERT, S. a DIXON, S. (2018). Wave-U-Net: A Multi-Scale Neural Network for End-to-End Audio Source Separation. pages 334–340. ISSN 13514180. doi: arXiv:1806.03185v1. URL <http://arxiv.org/abs/1806.03185>.
- STURM, B. L. (2013). Classification accuracy is not enough. *Journal of Intelligent Information Systems*, **41**(3), 371–406. ISSN 0925-9902. doi: 10.1007/s10844-013-0250-y. URL <https://link.springer.com/content/pdf/10.1007{ }2Fs10844-013-0250-y.pdf>.
- TACHIBANA, H., ONO, T., ONO, N. a SAGAYAMA, S. (2010). Melody line estimation in homophonic music audio signals based on temporal-variability of melodic source. *ICASSP, IEEE International Conference on Acoustics, Speech and Signal Processing - Proceedings*, (May 2014), 425–428. ISSN 15206149. doi: 10.1109/ICASSP.2010.5495764.
- VAN DEN OORD, A., DIELEMAN, S., ZEN, H., SIMONYAN, K., VINYALS, O., GRAVES, A., KALCHBRENNER, N., SENIOR, A. a KAVUKCUOGLU, K. (2016a). WaveNet: A Generative Model for Raw Audio. pages 1–15. URL <http://arxiv.org/abs/1609.03499>.
- VAN DEN OORD, A., KALCHBRENNER, N., VINYALS, O., ESPEHOLT, L., GRAVES, A. a KAVUKCUOGLU, K. (2016b). Conditional Image Generation with PixelCNN Decoders. URL <http://arxiv.org/abs/1606.05328>.
- YANG, L.-C., CHOU, S.-Y. a YANG, Y.-H. (2017). MidiNet: A Convolutional Generative Adversarial Network for Symbolic-domain Music Generation. URL <http://arxiv.org/abs/1703.10847>.

Seznam obrázků

1.1	Příklad vstupu a výstupu metody pro extrakci melodie. přidat zvukový příklad do přílohy	3
1.2	Zvuk klarinetu, tóny s různou výškou a dynamikou, 25 milisekund signálu se vzorkovací frekvencí 44 100 Hz. nějak uvést zdroj zvuku https://www.philharmonia.co.uk/explore/sound_samples/clarinet?p=3	4
1.3	Zvuk klarinetu, absolutní hodnota výstupu Fourierovy transformace signálu délky 4096 s oknem typu Hamming.	5
1.4	lorem ipsum	6
5.1	Diagram architektury CREPE, multiplikační koeficient 16x.	24
5.2	Výsledky experimentu s různými kapacitami modelu.	27
5.3	Architektura CREPE s různou jemností diskretizace.	28
5.4	Histogramy vzdálenosti chybného odhadu, výstup prvního modelu má rozlišení 50 centů, výstup druhého 10 centů.	28
5.5	Architektura CREPE, vliv rozptylu cílové distribuce.	29
5.6	Architektura CREPE, vliv rozptylu cílové distribuce.	30
5.7	Architektura CREPE, vliv multirezoluční vstupní konvoluční vrstvy.	31
5.8	Vrstvení obyčejných konvolucí s lineárně rozšiřovaným dosahem, obrázek převzat z van den Oord a kol. (2016a).	32
5.9	Vrstvení dilatovaných konvolucí s exponenciálně rozšiřovaným dosahem, obrázek převzat z van den Oord a kol. (2016a).	32
5.10	Architektura WaveNet upravená pro kompletní přepis skladeb, upraveno na základě Martak a kol. (2018).	33
5.11	Vývoj ztrátové funkce při učení architektury Martak a kol. (2018) pro extrakci melodie. Zatímco hodnoty pro trénovací množinu mají klesající tendenci, hodnoty na validační množině rostou, síť se velmi rychle přeučuje.	33
5.12	Úprava posledních vrstev WaveNet architektury.	34
5.13	Architektura WaveNet, vliv počtu filtrů dilatačních vrstev a skip propojení.	35
5.14	Architektura WaveNet, systematické prohledávání počtu dilatačních vrstev a bloků, vlevo hodnoty RPA, vpravo RCA.	36
5.15	Architektura WaveNet, vliv velikosti šířky kernelu dilatací.	37
5.16	Architektura WaveNet, vliv výstupní transformace skip propojení.	38
5.17	Architektura WaveNet, vliv velikosti první konvoluce.	38
5.18	Architektura WaveNet, vliv návrhu posledních vrstev.	39

Seznam tabulek

3.1	Souhrnná tabulka se základními informacemi o veřejně dostupných datasetech.	15
5.1	Počty filtrů v konvolučních vrstvách v architektuře CREPE v závislosti na multiplikačním koeficientu.	26
5.2	Výsledky pokusu o replikaci. Přesnosti nejsou přímo srovnatelné kvůli různým evaluačním strategiím.	26
5.3	Výsledky experimentu s různými kapacitami modelu.	27
5.4	Architektura CREPE s různou jemností diskretizace.	27
5.5	Architektura CREPE, vliv rozptylu cílové distribuce.	29
5.6	Architektura CREPE, vliv šířky vstupního okna.	30
5.7	Počet filtrů prvních vrstev multirezoluční vstupní konvoluční vrstvy.	30
5.8	Architektura CREPE, vliv multirezoluční vstupní konvoluční vrstvy.	31
5.9	Architektura WaveNet, vliv počtu filtrů dilatačních vrstev a skip propojení.	35
5.10	Architektura WaveNet, dosah a kapacita v závislosti na dilatačních počtu vrstev a bloků.	36
5.11	Architektura WaveNet, vliv velikosti šířky kernelu dilatací.	37
5.12	Architektura WaveNet, vliv výstupní transformace skip propojení.	37
5.13	Architektura WaveNet, vliv velikosti první konvoluce.	38
5.14	Architektura WaveNet, vliv návrhu posledních vrstev.	39

Seznam použitých zkratek

Přílohy